

SH-15

无人艇与无人机协同区域封控博弈 决策模型

安徽工业大学

2025 年 08 月

目录

1 设计说明	4
1.1 国内外研究现状分析	4
1.1.1 国内研究现状	4
1.1.2 国外研究现状	8
1.1.3 研究现状总结	8
1.2 模型设计思路	9
1.2.1 影响结果因素分析	9
1.2.2 研究思路	11
1.3 模型技术路线	12
1.3.1 技术路线概述	12
1.3.2 模型设计方法详细阐述	13
1.3.3 创新性与合理性	31
1.4 算法模型运行流程	32
1.4.1 整体控制流程	32
1.4.2 UAV 能量管理流程（energy.py）	38
1.4.3 博弈决策模型（game.py）	39
1.5 实际应用中的工程方法	41
1.5.1 模块化设计与解耦合	41
1.5.2 基于博弈论的任务分配策略	42
1.5.3 闭环航点与自动返航机制	42
1.5.4 动态布防与前推策略	43
1.5.5 能量与调度的统一管理	43
2 自测结果	44
2.1 无人艇与无人机系统配置分析	44
2.2 仿真过程与战术效果评估	44
2.2.1 模拟起始与无人机侦察阶段	44
2.2.2 接触与首次分配阶段	46
2.2.3 交战与首个目标锁定	48
2.2.4 战局推进与连续打击	50
2.2.5 最终战果与残局处理	53
2.3 核心算法性能深度分析	54
2.4 模拟模型准确性与有效性分析	55

3 使用说明	55
3.1 运行环境	55
3.2 代码目录结构	56
3.3 运行步骤	56
3.3.1 运行仿真（生成日志）	56
3.3.2 日志回放可视化	57
3.4 常见问题解决	58
3.5 高级配置	58
3.6 关键参数	58

1 设计说明

1.1 国内外研究现状分析

集群博弈算法（Clustered Game Theory Algorithms）近年来在多个领域中得到了广泛应用，如多智能体系统、资源分配、网络安全等。集群博弈算法的目标是通过博弈理论模型对多个集群之间的相互影响进行分析，以优化集群内外的合作或竞争策略。近年来的集群博弈算法大多结合了博弈论的经典模型（如纳什均衡、演化博弈、合作博弈等）和机器学习、深度学习等先进方法。

在基本集群博弈算法中，参与者（或博弈者）通常被表示为一个集合 $N = \{1, 2, \dots, n\}$ ，其中每个博弈者可能属于某个集群 $C_i (i = \{1, 2, \dots, m\})$ 。集群博弈的关键在于博弈者之间的相互作用、集群内部与集群间的博弈规则，以及对博弈结果的期望。

假设有 m 个集群，每个集群内有 n_i 个博弈者，其中 $\sum_{i=1}^m n_i = n$ ，集群内博弈者的行为遵循某种策略集合 $S_i = \{s_{i1}, s_{i2}, \dots, s_{in_i}\}$ ，集群间的博弈则依据博弈者的选择来进行互动。一个博弈者的收益函数通常可以表示为：

$$u_i(s_1, s_2, \dots, s_n) = \sum_{j \in C_i} f_{ij}(s_j)$$

其中， $f_{ij}(s_j)$ 表示表示博弈者 i 在集群 C_i 内与其他博弈者的互动收益， s_j 是博弈者 j 的策略。

1.1.1 国内研究现状

针对无人集群在高动态、强对抗环境下的自主协作与拓扑动态重构问题，国内学者在演化博弈、强化学习、多智能体决策优化、装备体系效能评估等方面开展了大量研究，取得了一定进展。

在装备体系作战效能评估方面，张国辉等（2024）提出了基于多智能体博弈强化学习（RLoMAG）的装备体系作战效能评估方法，将装备体系对抗建模为多智能体马尔可夫博弈过程，并给出包括智能体建模、博弈算法设计、效能指标设定在内的评估框架，有效支持无人集群作战效能定量分析；在装备体系作战效能评估方面，张国辉等（2024）提出了基于多智能体博弈强化学习（RLoMAG）的装备体系作战效能评估方法，该方法将装备体系对抗建模为多智能体马尔可夫博弈过程，并给出了包括智能体建模、博弈算法设计、效能指标设定在内的评估框架，以支持无人集群作战效能的定量分析。该方法主要采用平均场强化学习（Mean Field Reinforcement Learning, MFRL）作为核心集群博弈算法。

该方法采用平均场强化学习（MFRL）算法，在处理大规模多智能体博弈时具有较好的收敛性。主要分为以下几个部分：

(1) 值函数与博弈收益函数的映射：智能体 i 在策略 π 下的状态值函数 $v_{i,\pi}(s)$ 被定义为累积折扣期望奖励：

$$v_{i,\pi}(s) = \sum_{t=0}^{\infty} \gamma^t E_{\pi,p}[r_{i,t}|s_0 = s, \pi]$$

基于此，贝尔曼方程将智能体的动作值函数 $Q_{i,\pi}$ 表示为：

$$Q_{i,\pi}(s, a) = r_i(s, a) + \gamma E_{s' \sim p}[v_{\pi}^i(s')]$$

状态值函数 $v_{i,\pi}(s)$ 也可以表示为：

$$v_{i,\pi}(s) = E_{a \sim \pi(s)}[Q_{i,\pi}(s, a)]$$

博弈收益函数定义为所有智能体状态值函数的总和：

$$\bigcup_{\pi_{SoS_1}, \pi_{SoS_2}}^{SoS_1} = \sum_{i=1}^N v_{i,\pi}(s)$$

(2) MFRL 算法的迭代更新：MF-Q 算法的核心公式为：

$$Q^{MF}(s, a) = E_{s' \sim p}[r(s, a) + \gamma v^{MF}(s')]$$

其中智能体 i 的值函数 $v_i(s)$ 考虑了其探测范围内的智能体之间的相互作用：

$$v_i(s) = \sum_{a_i} \pi_i(a_i|s, \bar{a}_i) E_{\bar{a}_i(a_{-i}, \pi_{-i})}[Q_i(s, a_i, \bar{a}_i)]$$

智能体 i 的动作值函数 $Q_i(s, a)$ 被近似为只包含其探测范围内智能体之间的相互作用：

$$Q_i(s, a) = \frac{1}{N} \sum_{i,j \in N_i} Q_i(s, a_i, a_j) \approx Q_i(s, a_i, \bar{a}_i)$$

动作值函数 $Q_i(s, a)$ 通过以下公式进行迭代更新：

$$Q_{i,t+1}(s, a_i, \bar{a}_i) = (1 - a)Q_{i,t}(s, a_i, \bar{a}_i) + a[r_i + \gamma v_{i,t}(s')]$$

其中 a 为学习率，智能体 i 的策略 $\pi_{i,t}$ 通过玻尔兹曼分布得到：

$$\pi_{i,t}(a_i|s, \bar{a}_i) = \frac{\exp(\beta Q_{i,t}(s, \bar{a}_i, a_j))}{\sum_{a_j \in A_i} \exp(\beta Q_{i,t}(s, \bar{a}_i, a_j))}$$

在博弈搜索算法优化方面，管延霞等（2022）研究了面向多智能体博弈的并行蒙特卡洛树搜索算法，通过胜率估值传递的并行框架提升了资源利用率与决策效率，适应动态空间的指数级增长问题。主要分为以下几个部分：

(1) 胜率估值向量合并：主进程通过以下公式汇总所有子进程的胜率估值向

量:

$$\sum_{i=1}^n w_i x_i$$

(2) 节点估值函数:

$$value = \arg \max_{j \in [1..m]} \frac{y_j}{c_j} + \frac{\sqrt{\sum_{k=1}^{\infty} c_k}}{1 + c_j}$$

此外，刘雨舟等（2023）提出了基于多智能体强化学习的博弈 Petri 网（MARL-GPN），将攻防事件转化为效益矩阵，并在学习周期内达成纳什平衡，用于动态安全场景下的有效变化域挖掘，该模型旨在解决传统变化挖掘算法无法在动态博弈场景下有效验证变化域的问题，通过将攻防双方视为多智能体，利用多智能体强化学习实现动态博弈以获得最优策略，从而判断变化行为是否符合最佳收益，并实现变化域的有效性验证。

以下是该算法的详细数学模型:

(1) 基本概念: Petri 网 (Petri Net, PN):

$$PN = (P, T, F)$$

P 为有限库所集, T 为有限变迁集, F 为 Petri 网的流关系。

博弈 Petri 网 (Game Petri Net, GPN):

$$GPN = (P, T, F, R, U, D, M)$$

R 为博弈者的有限集合, U 是博弈者的效用函数, D 为决策的有限集, M 为一个有限标识集。

(2) 多智能体强化学习 (Multi-Agent Reinforcement Learning, MARL):

当多个智能体与环境交互时, 会形成一个多智能体系统。智能体 r_i 的总收益 U 代码段计算如下:

$$U_{r_i}^{D_r, D_t}(p) = \sum_{k \geq 0} \gamma^k u_{r_i}(p_k, t_k, p_{k+1})$$

其中:

- a) D_t 表示智能体 r_i 所选择的策略;
- b) D_r 表示除 r_i 外所有智能体所选择的策略;
- c) p 表示智能体在博弈时刻 k 下所处的状态;
- d) γ 为损失系数;
- e) $u(p_k, t_k, p_{k+1})$ 为效益函数, 决定了智能体从当前状态 p_k 采取行为以转移到状态 p_{k+1} 时所产生的效益值。

(3) 纳什平衡 (Nash Equilibrium): 在状态 s 下, 若存在一组博弈策略 $(t_{r_i}^*, t_{r-i}^*)$, 当且仅当该策略组对于博弈双方都是最佳策略, 则称此时博弈达到纳什平衡, 该策略组为博弈的纳什平衡点。其需满足以下条件:

$$t_{ri}^* \in T_r^i, U_r^i(t_{ri}^*, t_{r-i}^*) \geq U_{ri}^i(t_{ri}^i, t_{r-i}^i)$$

以及:

$$\forall t_{r \rightarrow}^{i'} \in T_{r \rightarrow}^{i'}, U_{r \rightarrow}^{i'}(t_{r \rightarrow}^{i'}, t_{r \rightarrow i}^{i'}) \geq U_{r \rightarrow i}^i(t_{r \rightarrow}^{i'}, t_{r \rightarrow i}^i)$$

(4) MARL-GPN 模型: MARL-GPN 是在 GPN 的基础上引入 MARL 概念所提出的一种新型 Petri 网模型, 它是一个满足以下条件的七元组:

$$MARL - GPN = (R, P, T, F, U, D, E)$$

其中 $R = R_1, R_2, \dots, R_n$, $ninZ$ 表示所有参与博弈的智能体有限集合。 P, T, F, U, D 的定义与 GPN 中基本相同, 并根据 MARL 进行扩展。 E 代表一个有限的效益矩阵集, 用于存储攻防双方在不同策略下的收益。

赵芷若等 (2023) 则建立了基于多智能体博弈强化学习的无人机智能攻击策略生成模型, 并利用“颤抖的手完美”思想优化策略, 提高了攻击任务的多样性与实时性。以下是该算法的详细数学模型:

(1) 基于 MAPPO 的策略生成模型:

该模型采用多智能体近端策略优化 (Multi-agent Proximal Policy Optimization, MAPPO) 算法来训练智能体, 以找到最优的攻击策略。

在 MAPPO 算法中, 智能体 i 的价值函数 $V^{\pi_i}(s)$ 定义为在策略 π_i 下, 从状态 s 开始的预期累积奖励:

$$V^{\pi_i}(s) = E_{\pi_i}[R_i(s_t) | s_t = s]$$

其中, $R_i(s_t)$ 表示智能体 i 从时刻 t 开始的折扣累积奖励。

动作-价值函数 $Q^{\pi_i}(s, a_i)$ 表示在状态 s 下, 智能体 i 采取动作 a_i 后的预期累积奖励:

$$Q^{\pi_i}(s, a_i) = E_{\pi_i}[R_i(s_t) | s_t = s, a_t = a_i]$$

优势函数 $A^{\pi_i}(s, a_i)$ 则表示在状态 s 下采取动作 a_i 相对于平均策略的优势:

$$A^{\pi_i}(s, a_i) = Q^{\pi_i}(s, a_i) - V^{\pi_i}(s)$$

(2) 策略更新: MAPPO 算法通过最大化以下目标函数来更新智能体的策略 θ_i :

$$L(\theta_i) = E_{s_t \sim \rho_{\pi_{old}}} [\min(r_t(\theta_i) A_t, \text{clip}(r_t(\theta_i), 1 - \epsilon, 1 + \epsilon) A_t)]$$

其中:

$$r_t(\theta_i) = \frac{p_{i,t}(\theta_i(a_t|s_t))}{p_{i,t}(\theta_{ext}(a_t|s_t))}$$

是新旧策略的概率比值， A_t 是优势函数。

总体来看，国内在该领域的研究已形成了从博弈机制设计—学习算法优化—作战效能评估—仿真验证的较完整技术链，但在跨域异构集群协同、实时自适应拓扑优化与理论收敛性分析等方面仍有进一步提升空间。

1.1.2 国外研究现状

国外在无人集群自主协作、拓扑动态调整与任务分配方面起步较早，研究体系相对成熟，尤其在网络化演化博弈建模、分布式决策收敛性分析与鲁棒任务分配算法等方面积累了丰富的丰富成果。

在演化博弈与任务分配收敛性方面，Minggang Yu 等（2023）提出了一种基于演化博弈理论的分布式决策框架，用于不确定环境下的无人机集群任务分配。研究构建了局部效用与全局效用相结合的任务分配模型，并在网络化演化潜在博弈中推导了潜在函数，证明最优解为有限策略博弈的纯策略纳什均衡，提出的 POTVLLA 算法可在概率 1 下收敛至最优解；在快速自适应与鲁棒性方面，国外学者通过引入基于收益的时间变 Boltzmann 参数更新方法，使得无人集群在任务增减、节点失效等情况下依然能够保持较高的计算效率与任务完成率。在多智能体网络协作机制方面，国外研究通常将无人集群建模为具有社区结构的复杂网络，通过分析节点度分布、聚类系数等指标，指导拓扑重构与信息流优化，以增强协作稳定性和任务分配的全局最优性。

总体而言，国外研究更强调数学收敛性证明、分布式计算效率优化与复杂网络理论结合，并在大规模集群的实时适应性和跨任务通用性方面取得了较多成果。

1.1.3 研究现状总结

- a) 综合国内外文献可见，学者们针对无人集群拓扑自适应重构与协作决策问题的研究主要集中在以下几个方面：
- b) 演化博弈建模与策略优化——利用博弈论刻画集群节点的协作与竞争行为，设计可动态调整的策略收敛机制。
- c) 多智能体强化学习融合——引入课程学习、迁移学习、元学习等机制提升集群在高维、动态环境下的学习效率与鲁棒性。
- d) 作战效能定量评估——基于马尔可夫博弈、多智能体对抗模型，对装备体系作战效能进行可量化的评估与优化。
- e) 分布式任务分配与网络优化——结合复杂网络理论与分布式算法，提高任务分配的收敛速度与全局最优性。

目前，该领域的不足主要体现在跨域异构集群协作的统一建模、实时拓扑重构与全局最优的理论收敛性分析、以及算法在极端对抗环境下的稳定性验证等方面。深入

研究这些方向，将有助于实现无人集群作战效能的最优配置与自主协作水平的持续提升，丰富无人作战系统的理论体系并增强其实战应用价值。

1.2 模型设计思路

1.2.1 影响结果因素分析

在无人集群区域封控博弈问题的建模中，模型设计思路从多个维度考虑了各类可能影响任务执行效果的关键因素，并通过综合分析确定了各个关键因素之间的相互关系。通过深入剖析这些因素，我们可以更好地理解问题的复杂性，并在此基础上构建一个合理、有效的优化模型。以下是对影响结果的主要因素详细描述：

1.2.1.1 平台与载荷性能

无人集群的区域封控效果不仅仅依赖单个平台的性能，还需要平台和载荷之间的协同作用。在任务执行过程中，平台提供必要的机动性和行动能力，载荷则提供探测、定位和锁定等执行任务的能力。二者的协同配合可以确保区域封控任务的高效执行。具体来说，涉及以下几个方面：

- a) 无人艇的运动性能：无人艇的运动能力包括其最大航速、最小转弯半径、加速能力等因素，这些都直接影响无人艇的机动能力。尤其是在复杂和动态的作战环境中，无人艇需要具备较强的机动性，以快速响应变化的战场态势。例如，最小转弯半径决定了无人艇在狭窄区域内能否灵活转向，航速则直接关系到任务完成的时效性。在区域封控任务中，无人艇需要高效且迅速地覆盖目标区域，因此航速和转弯半径的性能要求较高。
- b) 传感器和载荷能力：无人艇的传感器系统（如雷达、光学传感器、红外传感器等）是其完成探测、识别和锁定敌方目标的基础。传感器的探测范围、精度、响应时间和抗干扰能力将直接影响任务执行的效果。如果传感器的性能较弱，无人艇可能无法及时发现黑方无人艇，进而影响后续的封控和拦截工作。因此，高性能的传感器系统对任务的成功执行至关重要。
- c) 电池续航与能源管理：能源消耗是无人艇设计中的关键问题，尤其在长时间任务和远程任务中，电池续航能力成为决定无人艇能否完成任务的关键因素。电池续航时间限制了无人艇在执行任务时的持续作战能力。因此，合理的能源管理和充电策略必须考虑到任务执行的时间需求以及无人艇的充电频率。电池容量较小的无人艇可能需要频繁返航充电，这不仅会降低任务效率，还可能让任务出现空窗期。

1.2.1.2 环境因素

环境因素是影响无人艇集群执行封控任务的重要外部条件，特别在动态环境下，这些因素对无人艇的路径规划、机动能力、任务执行的有效性及其安全性有着显著影响。具体而言，环境因素主要包括以下几方面：

-
- a) 海洋环境的动态性：海洋环境的变化，如风浪、潮汐、流速等因素，可能会对无人艇的稳定性和机动性产生较大影响。特别是无人艇的运动轨迹会受到流速和海浪波动的影响，可能导致路径规划偏差或机动不灵活，进一步影响任务的完成。此外，环境的变化还会影响传感器的精度和反应速度，增加任务的不确定性。因此，在建模过程中必须考虑到这些环境因素，采用适应性强的路径规划算法，以保证任务在动态环境下的有效执行。
 - b) 海域中障碍物的影响：在实际的海洋环境中，除了自然障碍（如岛屿、岩石等），还可能存在其他动态障碍，如船只或其他无人艇等。无人艇需要实时监控环境，识别潜在的障碍物并及时调整航线。障碍物的存在不仅增加了路径规划的复杂性，还可能带来碰撞风险。因此，无人艇在执行任务时，必须具备避障能力，并能根据实时环境信息进行路径调整。
 - c) 对抗性环境与敌方机动：在区域封控博弈中，黑方（敌方）的行动策略也是环境因素之一。黑方无人艇可能采取规避、欺骗、反制等方式，试图突破白方的封控区域，甚至反击白方无人艇。黑方无人艇的机动灵活性、应变能力以及智能决策能力，都对白方的封控策略产生直接影响。白方无人艇必须根据敌方的实时反应调整策略，做好应对敌方变化的准备。因此，建模时不仅要考虑静态的环境因素，还要关注动态的对抗过程。

1.2.1.3 策略与决策机制

策略是无人集群在封控任务中的决策依据，包括任务分配、目标优先级、协同作战策略等。策略的合理性直接决定了无人集群能否高效且有效地完成区域封控任务。具体来说，涉及以下几个方面：

- a) 任务分配与协同机制：无人集群的协同效率和任务分配策略是封控任务成败的关键。通过合理的任务分配，可以确保每个无人艇的任务不重叠且高效执行，避免资源浪费。根据不同任务需求采用集中式或分布式调度机制来进行任务分配，确保每个无人艇都能在合适的时机执行任务。
- b) 优先级分配与资源调度：在任务执行过程中，敌方的威胁等级往往是动态变化的，因此需要实时评估敌方的活动并优先处理高威胁目标。例如，当敌方无人艇逼近封控区域时，应优先调动无人艇进行拦截，而不应将资源浪费在相对低威胁的任务上。不同的任务可能具有不同的优先级。比如，在任务过程中，封控敌方某个关键区域可能比其他区域更为重要。因此，任务分配时要根据不同任务的紧急程度和重要性进行合理排序。
- c) 动态调整与实时响应：在区域封控过程中，环境和敌方的变化往往是动态的，因此策略需要具备实时调整的能力。无人集群应能够根据实际战场态势进行实时决策，如重新分配任务、调整巡逻路线等。采用基于博弈论或深度强化

学习的动态策略调整,可以使集群在复杂环境中获得更高的灵活性和适应性。

- d) 容错与冗余设计:无人集群的任务执行过程中,由于环境因素、设备故障或敌方干扰等原因,部分无人艇可能发生失效或退出任务。冗余设计确保在部分无人艇出现故障时,其他无人艇能够接管其任务,确保整个任务的持续性和完整性。容错策略确保集群即使在部分无人艇失败的情况下,整体任务仍能继续进行。例如,集群中的每个无人艇都能自适应任务和目标,避免依赖单一设备或路径造成的任务失败。

1.2.2 研究思路

团队的研究思路旨在解决无人艇在协同覆盖任务中的路径规划、任务分配与对抗策略问题。具体研究思路分为以下几个主要步骤:

1.2.2.1 区域划分与任务分配

无人艇在进行目标区域覆盖任务时,首先需要合理划分任务区域,使得每个无人艇能够高效地执行任务。团队采用了 **Boustrophedon** 单元分解法,这是一种将复杂区域划分为多个简单的凸多边形子区域的方法。通过确保每个子区域的边界内角不超过 180 度,保证了每个子区域都能用走字型的方式进行路径覆盖。在区域划分过程中,团队考虑了以下几个重要因素:

- a) 区域连通性:确保划分后的每个子区域都能完整生成走字型路径。
- b) 区域地理邻近性:为了减少路径的复杂性,将邻近的子区域分配给同一无人艇。
- c) 区域面积均衡性:避免某些无人艇承担过重的任务,导致路径代价过高。
- d) 区域可探测性:确保每个子区域都能被某一或多个无人艇的探测范围覆盖。

这一方法使得复杂的区域覆盖任务可以转化为多个简单子区域的覆盖任务,并为后续的路径规划和任务分配提供了清晰的结构。

1.2.2.2 多旅行商问题 (mTSP)建模与任务分配

任务区域的划分后,团队将任务分配问题转化为多旅行商问题(mTSP),即通过将每个子区域视为一个“站点”,将任务区域的覆盖转化为多旅行商的路径规划问题。mTSP的解决方案是通过遗传算法来进行优化任务分配,确保每个无人艇都能高效地执行自己的任务,并且最终能够找到最优的任务分配方案。

任务分配过程的具体技术步骤如下:

- a) 染色体编码:采用两段式编码方式,其中第一段表示目标区域的排列顺序,第二段表示各无人艇的任务分配。
- b) 遗传算法:利用遗传算法的交叉、变异等操作,优化无人艇的任务分配,寻找最优的任务执行序列。
- c) 适应度函数:适应度函数不仅考虑任务的成功执行次数,还包括路径的代价、

无人艇的效率等多个指标，进一步优化任务分配方案。

1.2.2.3 路径规划与运动约束

无人艇在执行任务时，路径规划至关重要。为确保路径能够平滑且满足无人艇的运动约束（如最小转弯半径），团队提出了基于 RRT（快速随机树）算法的路径规划方案。RRT 路径规划算法能够在复杂环境中寻找无碰撞的路径，同时保证路径的平滑性和无人艇的运动约束。该算法的创新之处在于通过随机采样生成路径，避免了传统路径规划方法在复杂环境中的局限性。

1.2.2.4 博弈论建模与对抗策略设计

对抗场景中，无人艇需要与敌方（如黑方无人艇）进行博弈，做出最优决策。团队引入了博弈论模型来模拟白方和黑方之间的对抗过程，分析双方的策略选择。在博弈过程中，白方无人艇需要协同合作，通过探测和锁定策略来拦截黑方无人艇，而黑方则需要突破防线并规避白方的锁定。

具体的博弈建模过程如下：

- a) 博弈模型：通过构建一个非合作的动态博弈模型，分析双方在每一决策周期的策略选择。
- b) 支付函数：根据白方和黑方的策略选择，量化双方的收益和损失，例如成功拦截黑方无人艇、避免被锁定等。
- c) 策略优化：通过博弈论的分析，优化白方和黑方的行动策略，确保双方在对抗中能够最大化自身的收益。

这一部分创新地结合了博弈论与无人艇任务的协同与对抗，提出了适用于动态对抗场景的策略模型。

1.3 模型技术路线

1.3.1 技术路线概述

在针对无人艇的协同覆盖任务中，团队提出了一个综合的技术路线，旨在通过区域划分、任务分配、路径规划、对抗策略等多个模块协同工作，优化无人艇的区域封控与对抗能力。技术路线的关键环节包括区域划分、任务分配、路径规划与调度、博弈模型的应用等。

团队的技术路线涉及以下几大核心步骤：

- a) 区域划分与任务分配：使用 Boustrophedon 单元分解法将目标区域划分成多个凸多边形子区域，确保区域内的每个子区域都可以使用走字型模式进行路径覆盖。此方法能够有效减少路径规划的复杂度，提高区域封控的效率。将划分后的子区域转化为多旅行商问题（mTSP），通过遗传算法进行优化任务分配，确保每个无人艇能够高效完成任务区域的覆盖。
- b) 路径规划：采用 RRT 路径规划算法，为每个无人艇规划适应性强且符合运

动约束的路径。路径规划不仅要求避免与其他无人艇碰撞，还需确保路径的平滑性和最小转弯半径等约束条件得到满足。

- c) 博弈模型与对抗策略：建立非合作博弈模型，模拟白方与黑方无人艇的对抗情境。通过设计支付函数，量化双方的收益与风险，结合动态博弈与重复博弈的框架，优化无人艇的决策策略。团队采用多智能体马尔可夫决策过程（MAMDP）与深度强化学习（DRL），使无人艇能根据环境的实时变化调整策略，提高整体系统的适应性和灵活性。
- d) 调度和动态优化：针对无人艇调度问题，使用多目标优化算法（NSGA-II）进行离线优化，生成基准调度方案，并结合实时调度调整任务。通过该方法，能够在多个目标之间找到最佳平衡。
- e) 任务协同与负载均衡：在多无人艇协同作战过程中，团队通过任务优先级排序和协同控制机制，优化任务分配，确保资源不浪费且各无人艇的任务执行效率最大化。

1.3.2 模型设计方法详细阐述

团队的模型设计方法结合多种技术理论，通过模块化设计来解决无人艇协同任务中的各类挑战。设计方法可以分为以下几个部分：

1.3.2.1 Boustrophedon 单元分解法与mTSP建模

基于 boustrophedon 单元分解法对目标任务区域进行划分，实现步骤如下：

- a) 分解为凸多边形：将复杂区域分割成多个凸子区域，确保每个子区域边界内角不超过 180 度。
- b) 合并子区域：通过延伸边界内角并合并相邻子区域，形成更简单的覆盖单元。
- c) 路径规划：对每个子区域应用 Boustrophedon 模式生成覆盖路径，最终合并为全局路径。
- d) 根据上述步骤，将凸边形区域分解为规则的走字形子区域，最终输出若干子区域集合【A1, A2, A3.....An】

接着将子区域转化为多旅行商问题建模，任务区域通过 Boustrophedon 单元分解方法被划分为 N 个可遍历的子区域，其中 N 应明显大于 USV 数量 M（如 N=15~20）划分依据包括：

- a) 区域连通性：确保每块区域可完整生成走字型路径；
- b) 区域地理邻近性：优先将靠近同一部署 USV 的子区域打包；区域面积均衡性：避免某一 USV 任务过重而路径代价过高；
- c) 区域可探测性：每块区域必须完全落入某一或多个 USV 的探测/锁定范围。

通过上述约束和规则，将区域划分转化为满足约束的 mTSP输入，为后续任务调度提供建模依据。根据题目条件可知，现有五个无人艇，N 个子区域，现将每一个子

区域视为一个站点，总体目标为最小化所有无人艇路径总代价，满足：

$$\min \sum_{k=1}^M \sum_{i \in V \cup \{0\}} \sum_{\substack{j \in V \cup \{0\} \\ j \neq i}} c_{ij}^k x_{ij}^k$$

其中每个子区域只能被一个无人艇访问：

$$\sum_{k=1}^M \sum_{i \in V \cup \{0\}} x_{ij}^k = 1, \forall j \in V$$

流守恒（每艘艇出度=入度）：

$$\sum_j x_{ij}^k - \sum_j x_{ji}^k = 0, \forall i \in V, \forall k$$

考虑运动学，将区域重心或入口/出口点作为节点坐标 $q_i = (x_i, y_i, \psi_i)$ 第 k 艘艇的最短可行路径长度（前进受限、最小转弯半径）使用 Dubins路径：

$$c_{ij}^k = \text{DubinsLength}(q_i, q_j, R_{\min})$$

每个无人艇从自身初始位置出发，最终返回结束任务。转换完成后使用遗传算法求解mTSP。

为应对目标动态变化与多无人艇协同需求，避免同一无人艇连续两次锁定同一目标，在动态环境中使用固定时间窗口或限定规划目标数量，减少路径过时风险。团队设计了适应多旅行商问题的遗传算法优化流程：

- a) 染色体编码：采用两段式编码，第一段表示目标序列（长度为 $2N$ ，每个目标出现两次，表示需两次锁定）。第二段表示分割点向量（长度为 $m-1$ ，其中 m 为白方无人艇数量），将目标序列切分为 m 段，对应 m 架无人艇的任务。
- b) 适应度函数：综合考虑拦截效果、效率、安全性与时间因素：

$$\text{Fitness} = w_1 \times \text{成功锁定目标数} + w_2 \times \text{白方总锁定次数}$$

$$- w_3 \times \text{白方被锁定次数} - w_4 \times \text{碰撞次数} - w_5 \times \text{总时间}$$

其中 $w_1 \sim w_5$ 为权重，值由任务优先级设定。适应度计算通过仿真模拟目标运动与拦截过程完成。

- c) 交叉操作：列部分采用 OX（有序交叉）或 PMX（部分匹配交叉），保证每个目标恰好出现两；分割点部分保证分割点数量固定，使用单点交叉或均匀交叉进行交换。
- d) 变异操作：排列部分通过随机交换、子序列反转、任务重定位等操作，保持目标出现次数约束；分割点部分通过随机移动分割点位置，或通过调整分割

点实现任务转移（跨无人艇调度）。

1.3.2.2 运动学与路径规划（RRT + 曲率约束 / Dubins）

在协同覆盖与拦截任务中，无人艇（USV）的路径规划需要同时满足运动学约束和环境约束。运动学约束包括最小转弯半径、最大航向变化速率和速度范围；环境约束包括障碍物回避和安全距离保持。主要分为以下步骤：

假设无人艇在二维平面内航行，其状态向量为：

$$s(t) = (x(t), y(t), \psi(t))$$

其中， $x(t), y(t)$ 表示无人艇在全局坐标系下的位置； $\psi(t)$ 表示航向角（以全局 x 轴为参考，逆时针为正）。

控制变量为：

$$u(t) = (v(t), \omega(t))$$

其中， $v(t)$ 表示线速度， $\omega(t)$ 表示角速度（航向角变化率）。

在此基础上，无人艇的运动学方程可表示为：

$$\begin{cases} \dot{x}(t) = v(t)\cos\psi(t), \\ \dot{y}(t) = v(t)\sin\psi(t) \\ \dot{\psi}(t) = \omega(t) \end{cases}$$

并且满足物理约束：

$$v_{min} \leq v(t) \leq v_{max}, |\omega(t)| \leq \omega_{max} = \frac{v(t)}{R_{min}}$$

其中， R_{min} 表示最小转弯半径，由船体尺寸与操舵能力决定； ω_{max} 表示最大允许的角速度，反映了最小曲率限制。

在路径规划中，无人艇一般不能后退且转向受最小半径约束，两点之间的最短可行路径为 Dubins 路径。Dubins 路径由直线段（Straight, S）和半径为 R_{min} 的圆弧段（Curve, C）组合而成，共有以下 6 种可能的类型：

$$T = \{LSL, LSR, RSL, RSR, RLR, LRL\}$$

其中 L/R 分别表示左转/右转， S 表示直线航行。给定起点 $q_{start} = (x_s, y_s, \psi_s)$

和终点 $q_{goal} = (x_g, y_g, \psi_g)$ ，最短路径长度为：

$$DubinsLength(q_{start}, q_{goal}, R_{min}) = \min L_{type}$$

其中 L_{type} 表示对应类型路径的总长度，计算时需考虑圆心位置、切点位置和直线段长度的几何关系。

Dubins 路径适合无障碍的两点最短路径计算，但在实际海域中，可能存在岛屿、礁石或禁航区，这时需用随机采样法（RRT）规划路径。具体步骤如下：

- 从起点开始随机采样可行状态 s_{rand} （包含位置与航向角）；
- 在采样树中找到最近节点 s_{near} ；

- c) 通过Dubins路径连接 s_{rand} 和 s_{near} ，若路径无碰撞则加入树中；
- d) 重复步骤 a)-c)，直到到达目标区域。

曲率约束处理方式包含在采样时直接施加运动学方程约束，确保生成的轨迹可执行，在树扩展时强制连接段为 Dubins 路径。

由于 RRT 路径通常呈折线状，为了提升航迹平滑性和可执行性，需要进行后处理：

- a) 样条插值（Cubic Spline）：将路径节点拟合成连续可导曲线
- b) 曲率限制：检查拟合曲线的瞬时曲率 $\kappa(s)$ ，若 $|\kappa(s)| > 1/R_{min}$ ，则调整控制点或增加过渡段；
- c) 局部优化：利用梯度下降或迭代最近点法（ICP）微调路径，使其长度最短且保持可行。

为了在优化算法中平衡不同性能指标，可将路径质量建模为加权代价：

$$J(P) = \alpha_k \cdot L(P) + \alpha_k \int |\kappa(s)|^2 ds + \alpha_T \cdot T(P) + \alpha_{prox} \sum prox_penalty$$

其中， $L(P)$ 表示路径总长度； $\kappa(s)$ 表示路径曲率，积分项用于惩罚急转弯； $T(P)$ 表示总航行时间（由速度分布积分得到）； $prox_penalty$ 表示与其他艇或障碍的距离惩罚，通常定义为

$$prox_penalty = \max(0, \frac{d_{safe} - d}{d_{safe}})$$

其中 d 为当前最小距离， d_{safe} 为安全距离阈值。

在无人机数量有限、能源有限且需要持续覆盖指定区域的情况下，如何设计无人机的起降、巡逻路径和轮换策略，以最大限度地保证突破线附近区域的持续探测覆盖，同时确保无人机能够及时返回无人艇充电并再次投入任务。

在飞行过程中，无人机的电量按照耗电速度线性下降：

$$E_{current,i}(t) = E_{start,i} - r_{discharge} \times (t - t_{flight,start,i})$$

其中， $E_{start,i}$ 表示飞行开始时的电量， $r_{discharge} = 0.833\%/minute$

在充电过程中，无人机的电量按照充电速度线性上升：

$$E_{current,i}(t) = E_{start,i} - r_{charge} \times (t - t_{charge,start,i})$$

其中， $E_{start,i}$ 表示飞行充电开始时的电量， $r_{charge} = 0.333\%/minute$

无人机的电量从100%到0%的滞空时间为2hours。每次起飞前，无人机需要预留足够的电量用以返回到最近的无人艇充电。无人机探测扇形：半径 60 km，中心角 60°。起始五架无人机满电。

假设无人机*i*当前位于 (x_i, y_i) ，要返回无人艇*j*当前位于 (x_j, y_j) ，由欧几里距离得：

$$D_{i,j} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}$$

使用匈牙利匹配做无人机到监视扇区到 USV 的分配，考虑能量约束与预留返航能量。用改进 GA（TSP 变体）求解各无人机在其负责扇区内的巡逻点顺序与路径长度（参考 GA + QuickNav 的 TSP 思路，尽管无障碍但仍可用 GA 优化巡逻序列）；若需要在线修正，用 *RRT/PLRTA* / 重新规划（滚动时域）。

以时间窗 / 能量阈值为触发条件，触发无人机返航或换班到任一 USV。充电策略采用优先级：返回到最近且电量充足的 USV；若多无人机同时需求，USV 采用队列或按紧急度（剩余电量比）分配充电顺序。

对“哪个无人机巡逻哪个角度/扇区”采用完全信息静态博弈（离散时间、白方多玩家），构造收益函数（覆盖收益 - 能耗代价 - 未覆盖惩罚）；求纯策略纳什均衡，若不存在用复制子动力学逼近混合策略 NE（用于分配初始扇区/权重）。

目标函数（线性化）：

$$\max \sum_t \sum_s \sum_i w_s x_{i,s,t} - \alpha \sum_t \sum_i c_i(t)$$

其中 w_s 为扇区 s 的权重（重要性）， $c_i(t)$ 为无人机 i 在 t 时段的能耗（%）， α 权衡参数。其中每个时刻每架无人机只能处于一个状态（巡逻或返航/充电）：

$$\sum_{ss} x_{i,s,t} + \sum_b y_{i,b,t} \leq 1, \forall i, t$$

电量动态（离散时间差分）：

$$E_{i,t+1} = E_{i,t} - \Delta t \times \rho_i(t) + r_{charge} \times \Delta t \times z_{i,t}^{charge}$$

其中 $\rho_i(t)$ 为即时耗电率（%/h），若以小时为单位， Δt 以小时计。若无人机选择返回某 USV，则必须保证返航所需能量小于当前剩余电量减去预留：

$$E_{i,t} - \text{energy cost to nearest USV}(\rho_i(t)) \geq \varepsilon_{return}, \forall i, t \text{ s.t. } y_{i,b,t} = 1$$

充电只能在 USV 上发生（位置信息约束）： $c_b = 1$ 。

$$z_{i,t}^{charge} \leq \sum_b y_{i,b,t}, \forall i, t$$

USV 充电位容量或同时充电数（有限）：

$$\sum_i z_{i,t}^{charge} \times 1_{\{on\ b\}} \leq C_{b,t}, \forall b, t$$

对每架无人机的 assigned 扇区内，生成若干巡逻关键点（覆盖目标或扇区中心轨迹点）；用 GA（TSP 变体）优化点序以最小化巡航距离/时间，得到航程估计 L_i 与预计耗电 c_i 。若速度、风等外部扰动被忽略，可用滚动时域，每 H 分钟重算一次路径；如果需要避障或随机事件，使用 RRT 做局部修正。其中 MathType（巡逻路径长度与电耗估算）：

$$L_i = \sum_{k=1}^{N_i-1} d(p_{i,k}, p_{i,k+1}) \quad c_i = \beta_{move} \times L_i / v_{avg} \quad (\text{转化为\%电量消耗})$$

其中 β_{move} 为单位距离对应的耗电转换系数；若只能用 %/h 表达，则将时间换算成小时再乘以 ρ_i 。

1.3.2.3 覆盖与评估指标

覆盖与评估指标的目标是用数学量化“区域被探测/监视”的程度、多个无人机的利用效率与冗余浪费，从而为任务分配、轨迹规划和在线重规划提供可优化的目标函数和约束。核心思想是：

- 用每架无人机对空间点 $q = (x, y)$ 的检测概率函数 $p_i(r)$ 描述单架无人机的探测能力（把二值硬阈值推广到连续概率以便可微优化）；
- 通过独立事件假设将单艇概率合成为点的被检测概率 $C(t, q)$ ；
- 在时空上对未被覆盖的面积-时间量、重叠面积、首次检测时间等指标进行积分或期望计算，得到量化目标；
- 若需梯度优化，给出这些指标对无人机位置或轨迹的导数表达式。

详细展开如下：

令第 i 架无人机在时刻 t 的位置为 $p_i(t)$ 。对于场上任意点 q ，定义距离为：

$$r_i(t, q) = \| p_i(t) - q \|$$

单架无人机检测概率 $p_i(r)$ 使用高斯衰减形式：

$$p_i(r) = \exp(-(\frac{r}{\sigma})^2)$$

在常用的“独立检测事件”假设下，点 q 在时刻 t 被至少一架无人机检测到的概率为

$$C(t, q) = 1 - \prod_{i=1}^M (1 - p_i(r_i(t, q)))$$

此处 M 表示无人机数量，若 p_i 为二值函数，则 $C \in \{0, 1\}$ ；若为连续函数，则 $C \in [0, 1]$ 。

定义时域为 $[0, T]$ ，空间监视域为 Ω 。连续时空未覆盖量定义为

$$U_{tot} = \int_0^T \iint (1 - C(t, q)) dq dt$$

归一化指标（便于多目标组合）：

$$\hat{U} = \frac{U_{tot}}{T \cdot Area(\Omega)} \in [0,1]$$

重叠反映多艇对同一区域的重叠覆盖，代表资源浪费或感知冗余。常用的二元近似度量时刻 t 的总双重覆盖面积：

$$O(t) = \sum_{1 \leq i < j \leq M} Area(S_i(t) \cap S_j(t))$$

其中， $S_i(t) = \{q: r_i(t, q) \leq R\}$ 表示第 i 艘无人艇的有效探测区域（若半径一致）。 S_i 和 S_j 为半径相等的圆，两圆心距 $d = \|p_i - p_j\|$ ，重叠区域可表示为两扇形面积之和减去两等腰三角形面积之和；扇形角由余弦定理确定，从而得到下式：

$$Overlap(d) = 2R^2 \cos^{-1}\left(\frac{d}{2R}\right) - \frac{d}{2} \sqrt{4R^2 - d^2}$$

若 $d > 2R$ ，则 $Overlap(d) = 0$ ；若 $d = 0$ ，则 $Overlap(d) = \pi R^2$ 。

若 $0 < d < 2R$ ，对 d 求导，并转化为对的偏导 p_i 可得：

$$\nabla_{p_i} Overlap(d) = \frac{d^2 - 4R^2}{\sqrt{4R^2 - d^2}} \cdot \frac{p_i - p_j}{d}$$

其中，方向项 $\frac{p_i - p_j}{d}$ 表示从 j 指向 i 的单位向量。该梯度可用于驱动艇彼此远离以减少重叠。

定义每艘无人艇在时间段 $[0, T]$ 的活跃指示函数：

$$a_i(t) = \begin{cases} 1, & \text{艇 } i \text{ 在时刻 } t \text{ 处于执行任务/巡逻/锁定状态} \\ 0, & \text{否则} \end{cases}$$

则每艘无人艇的利用率为：

$$u_i = \frac{1}{T} \int_0^T a_i(t) dt$$

给定点 q ，定义其首次检测时间：

$$T_{first}(q) = \inf\{t \geq 0: C(t, q) \geq \theta\}$$

其中阈值 θ 常取 1（二值模型）或 0.5 概率模型的中位阈值）。

若检测在离散时刻 t_k 发生，每次检测在时间 t_k 的成功概率为 p_k （由当前位置和 p_i 组合得到），则“首次成功在 t_k ”的概率为

$$P_r(\text{first at } t_k) = \left(\prod_{j < k} (1 - p_j)\right) p_k$$

对应的期望首次检测时间

$$\mathbb{E}[T_{frist}] = \sum_k t_k Pr(first \text{ at } t_k)$$

若对该点每单位时间到达一次检测尝试的平均速率为 λ ， λ 由艇的访问频率和探测时长估计。每次尝试成功概率为 P （近似不随时间变化），则成功发生为 Poisson 事件，hazard rate 为 λ_p ，首次检测时间服从指数分布，期望为：

$$\mathbb{E}[T_{frist}] = \frac{1}{\lambda_p}$$

若区域内不同点具有不同战略重要性，定义权重函数 $\omega(q)$ 。加权覆盖得分为

$$S = \int_0^T \iint_{\Omega} \omega(q) C(t, q) dq dt$$

归一化得分用

$$S^{\wedge} = \frac{S}{T \iint_{\Omega} \omega(q) dq}$$

对应的未覆盖区域的加权损失是

$$L_{\omega} = \int_0^T \iint_{\Omega} \omega(q) (1 - C(t, q)) dq dt$$

采用多目标组合与标量化策略，预先设权重，将常见目标集合标量化：

$$\min \gamma = \alpha \frac{U_{tot}}{U_{max}} + \beta \frac{O^-}{O_{max}} + \gamma \frac{E_{tot}}{E_{max}} + \delta \frac{-Util}{1}$$

其中， U_{tot} 表示未覆盖量，越小越好； $O^- = \frac{1}{T} \int_0^T O(t) dt$ 表示平均重叠，越小越好； E_{tot} 表示总能耗，越小越好； $-Util$ 表示利用率取负以转为最小化问题；分母为归一化量（上界），权重 $\alpha, \beta, \gamma, \delta \geq 0$ 由任务优先级决定。

若单艇检测概率 $p_i(r)$ 连续可导，则 $C(t, q)$ 对 p_i 可导。先定义：

$$Q(t, q) = \prod_{j=1}^M (1 - p_j(r_j(t, q))), \quad C(t, q) = 1 - Q(t, q)$$

对第 i 艘艇位置 p_i 在时刻 t 时固定，求梯度得：

$$\frac{\partial C}{\partial p_i} = -\frac{\partial Q}{\partial p_i} = -\left(\prod_{j=1}^M (1 - p_j(r_j))\right) \cdot \frac{\partial(1 - p_i(r_i))}{\partial p_i}$$

记为向量形式：

$$\nabla_{p_i} C(t, q) = \prod_{j \neq i} (1 - p_j(r_j)) p'_i(r_i) \frac{p_i - q}{r_i}$$

用梯度法来优化艇的轨迹，需要知道每艘艇的位置变化，会让 U_{tot} 变多还是变

少，以及变化多少。那么对整体未覆盖量 $Utot$ 的梯度向量：

$$\nabla_{p_i} Utot = - \int_0^T \iint_{\Omega} \nabla_{p_i} C(t, q) dq dt$$

离散化到网格，即：

$$\nabla_{p_i} Utot \approx - \sum_{k=1}^{N_t} \sum_g \nabla_{p_i} C(t_k, q_g) \Delta A_g \Delta t_k$$

其中， ΔA_g 表示单个网格单元的面积， Δt_k 表示时间步长。

如果某个艇离某个未覆盖的高权重区域很近，而且它一旦移动过去就能显著提高 $C(t, q)$ ，那么该点的 $\nabla_{p_i} C(t, q)$ 会比较大，梯度向量会指向那片区域。如果艇已经覆盖了某点，再靠近不会带来明显收益，则该点对梯度贡献接近 0。梯度的整体积分（或求和）把全局的这些局部贡献加起来，往哪个方向调动这艘艇的位置，能最快减少全局未覆盖量。

1.3.2.4 锁定（拦截）机制概率模型

在锁定（拦截）机制的概率建模中，首先需要明确一组核心参数。单次尝试的成功概率记为 $p = 0.8$ 。为了完全中和目标，往往要求达到一定次数的成功锁定，记为 k ，设定为 $k=2$ ，即需要成功两次才能使目标退出。在离散的行动模型下，每一次尝试都需要固定的执行时间，这段时间记作 $t_{freeze} = 5mine$ ，代表了艇从发起动作到完成一次锁定判定所用的时长。此外，每次成功锁定后，目标会进入冻结状态，此期间无法移动或容易被再次锁定。

用连续时间的到达模型，可以把每艘白方艇对目标发起锁定的尝试看作是一个 Poisson 到达过程，其到达率为 λ （单位为“次/单位时间”）。当有 r 艘艇同时参与对同一目标的尝试时，总的尝试到达率为

$$\Lambda = r\lambda$$

把每次尝试视为一次伯努利试验（成功概率 p ），直到获得第 k 次成功为止。令 T 为试验次数（即需要做多少次尝试才得到第 k 次成功）。则 T 服从负二项分布：

$$Pr(T = t) = \binom{k-1}{t-1} p^k (1-p)^{t-k}, \quad t = k, k+1, \dots$$

期望与方差为：

$$E[T] = \frac{k}{p}, Var(T) = \frac{k(1-p)}{p^2}$$

假设每次尝试耗时 $t_{attempt}$ ，且每次成功之后会导致（除最后一次外）一个确定的冻结时长 t_{freeze} ——即若要得到 k 次成功，总的时间为

$$T_{time} = t_{attempt} \cdot T + (k-1)t_{freeze}$$

因为第一次成功后会冻结一次，第 k 次成功后任务结束，不再加入额外冻结。由此得到期望：

$$E[T_{time}] = \frac{k}{p} t_{attempt} + (k-1)t_{freeze}$$

冻结是确定量，不贡献方差。遵循离散分布：

$$\Pr(T_{time} = nt_{attempt} + (k-1)t_{freeze}) = \Pr(T = n) = \binom{n-1}{k-1} p^k (1-p)^{n-k}$$

$$n = k, k+1,$$

由于并不是每一次尝试都会成功，因此成功事件本身也可以看作是一个 Poisson 过程，其速率等于总尝试速率乘以单次成功概率，即

$$\rho = \lambda p = r\lambda p$$

令 T_{succ} 为达到 k 次成功所需的时间（不计冻结），则 T_{succ} 服从 Erlang（整数形 Gamma）分布：

$$F_{T_{succ}}(t) = 1 - \sum_{n=0}^{k-1} e^{-\rho t} \frac{(\rho t)^n}{n!}$$

期望与方差：

$$E[T_{succ}] = \frac{k}{\rho} = \frac{k}{r\lambda p}, \text{Var}(T_{succ}) = \frac{k}{\rho^2} = \frac{k}{(r\lambda p)^2}$$

并且 CFD 为 Erlang 的 CFD 在 $t - (k-1)t_{freeze}$ 上的右移：

$$\Pr(T_{time} \leq t) = \begin{cases} 0, & t < (k-1)t_{freeze}, \\ 1 - \sum_{n=0}^{k-1} e^{-\rho(t-(k-1)t_{freeze})} \frac{(\rho(t-(k-1)t_{freeze}))^n}{n!}, & t \geq (k-1)t_{freeze} \end{cases}$$

“冻结期”为随机（指数化）——连续时间马尔可夫链（CTMC）近似。期不能或不应被视为完全确定时（例如冻结有随机恢复时间），可以把系统建成 CCTMC 尔可夫过程）。若把成功到达率（在任何活动态）记作 $\rho = r\lambda p$ 结恢复率（指数分布）记作 μ （期望冻结时长为 $1/\mu$ 则转移率矩阵 Q 按 transient states 形式）。

把 transient 状态设为向量 s ， t_i 表示从状态 i 到达吸收态 2 的期望时间。则对 CTMC 的标准结果，有线性方程组：

$$-\sum Q_{ij} t_j = 1, \quad \forall \text{ transient } i,$$

解出 t 即可得到从初态 t_0 的期望吸收时间。对上面简单链，用分步直观法可得到与之前一致的结果：

$$E[T_{time}] = \frac{1}{\rho} + \frac{1}{\mu} + \frac{1}{\rho} = \frac{2}{\rho} + \frac{1}{\mu}$$

其中， $\frac{1}{\mu}$ 表示冻结的平均时长。

采用 Poisson 成功过程模型，则到达/成功是按速率分配的：当第 k 个成功到来

之前的时间为随机 T_{succ} ，每艘艇 j 的尝试是 $Poisson(\lambda_j)$ 到时刻 T_{succ} 的尝试次数（期望）为 $\lambda_j E[T_{succ}]$ 。若要关心每艘艇贡献的成功次数，在不区分成功“先后”的条件下，条件于总共出现了 k 个成功，这 k 个成功在各艇之间服从多项分配，权重为各艇尝试率 λ_j ：

设总尝试率 $\Lambda = \sum_{j=1}^r \lambda_j$ ，则

$$E[\text{尝试数}_j] = \lambda_j E[T_{time}]$$

其中， $E[T_{time}]$ 在上文已给出。

在分析锁定机制的性能时，可以用多种概率模型来量化所需时间或尝试次数。首先，当任务由一系列相互独立的尝试组成，每次尝试成功的概率为 p ，标需要累计 k 成功才能被中和时，尝试次数 T 循负二项分布。其概率质量函数为

$$\Pr(T = t) = \binom{t-1}{k-1} p^k (1-p)^{t-k} \quad t = k, k+1, \dots$$

这一公式表示，在前 $t-1$ 次尝试中，必须恰好有 $k-1$ 次成功，第 t 次尝试再获得第 k 次成功。该分布的期望值与方差分别为

$$E[T] = \frac{k}{p}, \quad \text{Var}(T) = \frac{(1-p)}{p^2}$$

其中期望值反映了在平均意义下完成任务所需的尝试次数，而方差衡量了该次数的不确定性。

当尝试的发生时刻是随机的，且可以用 Poisson 过程建模时，更适合采用 Erlang（Gamma）分布模型。假设每艘艇的尝试到达率为 λ ，共有 r 艘艇参与，则总尝试到达率为 $\Lambda = r\lambda$ 。由于每次尝试成功的概率为 p ，成功事件的到达率为

$$\rho = \Lambda p = r\lambda p$$

在这种连续时间模型中，从开始到获得第 k 成功的时间 T_{succ} 服从 Erlang 分布，其概率密度函数为

$$f_{T_{succ}}(t) = \frac{\rho^k t^{k-1}}{(k-1)!} e^{-\rho t}, \quad t \geq 0$$

考虑冻结时间的情况，若每次成功后（除最后一次外）会固定冻结 t_{freeze} ，则总时间的期望为

$$E[T_{time}] = \frac{k}{\rho} + (k-1)t_{freeze}$$

其中， $\frac{k}{\rho}$ 对应纯粹等待 k 次成功的平均耗时， $(k-1)t_{freeze}$ 表示冻结所带来的额外延迟。

1.3.2.5 对抗博弈与多智能体学习模型

在多艇对抗场景中，最自然的数学框架是马尔可夫博弈（Markov Game），一个

标准的马尔可夫博弈由元组 $(S, \{A^i\}_{i=1}^n, P, \{r^i\}_{i=1}^n, \gamma)$ 给出, S 是全局状态空间 (包括所有艇的位置、速度、电量、目标状态等); A^i 是第 i 个智能体的动作空间 (例如机动、锁定、巡逻、返航、充电以及动作参数如航向角和速度); $P(s'|s, a^1, \dots, a^n)$ 定义从状态 s 在联合动作 $a = (a^1, \dots, a^n)$ 下转移到 s' 的概率; 每个智能体有自己的即时奖励函数 $r^i(s, a)$, 而 $\gamma \in (0, 1)$ 折扣因子。若系统为部分可观测情形, 则每个智能体仅获得观测 O_t^i , 其策略通常依赖于观测历史或信念状态; 这对应 Dec-POMDP 的形式化。

在此框架下, 智能体 i 的长期目标通常是最大化期望累计回报 $J^i(\pi) = E[\sum_{t=0}^{\infty} \gamma^t r_t^i]$ 期望按联合策略与环境过渡取。对应的状态值函数与动作值函数定义为

$$V_{\pi}^i(s) = E_{\pi, P}[\sum_{t=0}^{\infty} \gamma^t r_t^i | s_0 = s], Q_{\pi}^i(s, a) = E_{\pi, P}[\sum_{t=0}^{\infty} \gamma^t r_t^i | s_0 = s, a_0 = a]$$

对于每架无人机 i , 对每个时间步 t , 玩家选择一个扇区 $s \in S$ (或选择“待命/返回”)。收益函数 $U_i(s_i, s_{-i})$: 由覆盖收益、距离代价与能量成本组成:

$$U_i = G \times COV_i(s_i) - \lambda dist_i(s_i) - \mu \times \Delta E_i(s_i)$$

其中 $Cov_i(s_i)$ 为该无人机在扇区 s_i 提供的边际覆盖 (与其他无人机重复覆盖会被折扣), ΔE_i 为进入该策略预计耗电量, λ, μ 为权重。

计算每个无人艇的最佳响应集合:

$$BR_i(s_{-i}) = \operatorname{argmax} U_i(s_i, s_{-i})$$

若存在 $s^* = (s_1^*, \dots, s_n^*)$; 使得 $s_i^* \in BR_i(s_{-i}^*)$ (对所有 i 成立), 则为纯策略纳什均衡。若不存在纯策略 NE, 使用复制子动力学在离散策略空间上逼近混合策略 NE: 设每个无人机 i 在策略 s 的概率 $P_{i,s}(k)$, 迭代

$$P_{i,s}(k+1) = P_{i,s}(k) \frac{e^{\eta U_i(s, P_{-i}(k))}}{\sum_{s'} e^{\eta U_i(s', P_{-i}(k))}}$$

η 为学习率。迭代收敛时, 取概率最高的策略作为分配。该方法在多篇综述中作为混合策略 NE 的近似方法被推荐。

算法范式层面存在几大类主流方案, 各有适用场景。团队使用独立学习 (Independent RL, IQL): 每艘艇视其他艇为环境的一部分, 独立地学习自己的策略。IQL 简单易实现, 但在多智能体对抗中因环境非平稳 (其它智能体也在学习) 而难以稳定收敛。为此提出的实用范式是集中训练、分布执行 (CTDE): 训练阶段可访问全局信息并训练带有集中化 critic 的方法, 而执行阶段仅依赖各自可用的局部观测。其策略梯度形式可写为集中式优势加权的期望:

$$\nabla_{\theta} J^i \approx E_{s, a \sim D} [\nabla_{\theta} \log \pi_{\theta}^i(a^i | o^i) (Q_{\pi}^i(s, a) - b(s))]$$

其中 $b(s)$ 是基线 (如状态值) 用于减少方差, D 是经验分布。集中式 critic 的好

处是能够利用完整信息来估计更准确的梯度信号，从而缓解非平稳性。

在实际海域对抗中，部分可观测性（Dec-POMDP）极为常见：舰队成员对全局状态没有完全信息，策略必须基于历史观测序列 $O_t^i = (o_0^i, o_1^i, \dots, o_t^i)$ 。这使得策略表示常采用循环神经网络（RNN）或 Transformer 来编码历史为隐状态 h_t^i ，从而以 $\pi^i(a^i | h_t^i)$ 输出动作。若允许通信，可把消息 m_t^i 纳入策略输入或动作输出，实现显式协调；通信本身可作为学习任务的一部分（learned communication），并在 CTDE 框架下进行端到端训练。

从工程与安全角度考虑，博弈/强化学习系统常需满足约束（如碰撞避免、最低电量保证、通信约束）。带约束的强化学习可以表述为约束马尔可夫决策过程（CMDP）：在最大化主回报 $J(\pi)$ 的同时，要满足期望成本约束 $E\pi[\sum_t \gamma t c_t] \leq C$ 。一种常用的求解手段是拉格朗日乘子法，将约束并入拉格朗日：

$$L(\pi, \lambda) = J(\pi) - \lambda(E\pi[\sum_t \gamma t c_t] - C)$$

交替优化策略参数 π 与乘子 λ ，从而在训练中兼顾性能与安全。该框架也适用于多智能体环境中的团队层面安全约束。

训练技巧与稳态化策略在多智能体对抗中尤为关键。常见措施包括经验回放（对 CTDE 中的集中 critic 使用全局经验池）、目标网络与软更新以提高稳定性、优势函数归一化以降低方差、参数共享（同角色艇共享策略网络以加速学习）、以及对抗性正则化（训练时引入策略噪声或对抗对手以提升鲁棒性）。为应对学习过程中的非平稳性，常用对手建模、对手策略队列（维护历史策略集）或使用自我对弈 + 增量对手混合策略（policy pool）来逼近稳健解。

评估方面，应同时考察样本效率、收敛性、策略鲁棒性与任务层面指标（覆盖率 Ut_{tot} 、中和成功率、平均中和时间、碰撞次数、资源利用率与公平性指标等）。实验设计建议包含：基线算法（启发式规则、IQL、CTDE 算法如 MADDPG 或 QMIX）、不同对手策略（随机、启发式、学习型）、域随机化（扰动风/流、观测噪声）以及迁移测试（训练在仿真，测试在改变量的仿真环境中）。最后，在对抗环境中，采用自我对弈（iterative self-play）配合策略池和策略评估（Elo 或更丰富的对抗排名指标）是衡量算法长期进化能力与鲁棒性的良好实践。

1.3.2.6 在线执行与动态重规划模型

在线执行采用滚动时域（receding-horizon）策略：每隔 Δt_{plan} 秒基于当前观测与预测，求解一个短时域（horizon HHH）的优化问题，得到各艇在短期内的动作序列并执行第一段控制；以此循环直至任务结束。短期优化兼顾覆盖/拦截效能与安全/能量约束，并允许在有限计算预算内用启发或混合方法近似求解（例如把遗传算法的离线解作为 warm-start 或基线）。

把时间离散化，索引 $t = k, k + 1, \dots, k + H$ 对应真实时间 $t_k = k\Delta_t$ ，每步时长 Δ_t 。对第 i 艘艇，状态和控制量为

$$x_i(t) \in R^n (\text{通常 } x = (x, y, \psi, v, E)), u_i(t) \in R^m (\text{例如 } u = (a, \omega))$$

离散动力学写成

$$x_i(t + 1) = f(x_i(t), u_i(t)), \quad t = k, \dots, k + H - 1$$

并加上盒式约束：

$$v_{min} \leq v_i(t) \leq v_{max}, |\omega_i(t)| \leq \omega_{max}, E_i(t) \geq 0$$

在时刻 k 解下面的有限时域最优化问题，决策变量：

$$\{u_i(t)\}_{i=1..M, t=k..k+H-1}$$

目标：

$$\min J_k(\{x, u\}) = \sum_{t=k}^{k+H-1} (\alpha J_{cov}(t) + \beta J_{inter}(t) + \gamma J_{energy}(t) + \eta J_{col}(t))$$

其中，覆盖代价（越小越好，可用离散网格或目标点近似）：

$$J_{cov}(t) = \sum_{g \in G} w_g (1 - C(t, q_g)) \Delta A_g$$

能耗： $J_{energy}(t) = \sum_{g \in G} e(v_i(t)) \Delta t$

碰撞与安全软约束惩罚（强制性用硬约束）：

$$J_{col}(t) = \sum_{i < j} \phi(d_{safe} - \|p_i(t) - p_j(t)\|)$$

其中 $\phi()$ 是凸的罚函数（如平滑 ReLU），也可以把 $\|p_i(t) - p_j(t)\| \geq d_{coll}$ 作为硬约束。约束集合包括动力学（上式）、碰撞避免硬约束、航行约束、能量保证（保证在任何时刻有足够能量返航）：

$$\|p_i(t) - p_j(t)\| \geq d_{coll}, \forall i \neq j, \forall t \in [k, k + H]$$

返航约束（确保安全返航）：

$$E_i(t) \geq E_{return}(x_i(t)), \forall t$$

短时域里若将任务分配（谁去哪个目标/子区）作为决策，则会引入二元/整数变量表示第 i 艘艇在时间 t 服务目标 o ），导致混合整数非线性规划（MINLP）。实际实时性要求下，常用近似启发式替代策略。

调度周期 Δt_{plan} ：应设为能在下一次重规划前保证航迹安全的时间片。原则：

$$\Delta t_{plan} \leq \min\{\frac{d_{react}}{v_{max}}, T_{compute}\}$$

其中， d_{react} 为遇突发事件需要做出的最小安全位移， $T_{compute}$ 是求解器允许的

最大计算时间（实时性预算）。常见做法：把 Δt_{plan} 设为数秒到几十秒级，且保证能在 Δt_{plan} 内完成一次规划并下发首段控制。

以时间长度 $T_H = H\Delta t_{plan}$ 表示。选取原则为覆盖短期预期动作与使终端安全约束（返航、充电）可检查： T_H 应至少覆盖到达临界目标或完成一个局部任务所需的典型时间。 H 的大小与计算复杂度直接相关（复杂度随 H 增长）。

把上一次规划的剩余轨迹或离线 GA 给出的长期巡航计划作为初始可行解（warm-start）。对使用启发式求解器（局部 search、梯度法、SQP）尤为重要——能显著减少迭代数并提高实时可行性。

若在线求解失败或超时，应有安全后备策略（safety fallback）——例如执行上一周期的剩余轨迹、进入避障/原地盘旋或返回最近港口。这保证系统在任意时刻都有安全控制输入。

除固定周期外，可由下列事件触发即时 replanning：新目标发现、目标预测误差超阈、艇故障/掉线、碰撞危险、能量低于阈值。触发条件应与控制优先级挂钩（例如遇到紧急碰撞，优先避障不做覆盖最优化）。

离线用 GA / NSGA-II 在全局大 horizon 上搜索多目标 Pareto 集（覆盖-能耗-风险等），得到若干代表性长期方案（tour / depot schedule）。这些方案作为“高层策略库”。优势：能做更深搜索、花更多时间找到高质量全局解。

在每个滚动周期，用下述任一方式快速调整离线解：

- a) 局部启发式（2-opt、swap、insertion）对受影响片段做微调；
- b) 把离线解作为 GA 的初始种群（warm-start），但限制迭代次数与种群大小，保证满足实时预算；
- c) 对新出现任务只插入到最合适的艇路线上，而不改变其他艇路径（插入启发式）。

当在线允许一定的计算但不足以全局优化时，使用小代数、少量交叉/变异迭代的“快速 GA”，或者采用分布式 GA（各艇并行进化局部任务）。

为避免在线局部调整降级整体性能，保留上一轮离线/全局解作为参考，只有当局部解在评估指标上优于基线时才采用替换（保守更新策略）。

在短时域内对若干样本预测轨迹（基于噪声采样）并在目标函数中对所有情景求期望或最大化 worst-case:

$$\min E_{scen} [J_k(\{x, u\}; \text{scenario})]$$

把碰撞约束写为概率形式（允许很小概率违反）：

$$Pr(\|p_i(t) - p_j(t)\| \geq d_{coll}) \geq 1 - \epsilon$$

并通过保守近似（Chebyshev / Boole 协调）或线性化将其转化为确定性约束。

对不确定扰动做最坏情况优化（代价高但更保守），或采用 tube-MPC（在

nominal trajectory 周围维护可行的 tube)。用短期频繁 replanning 与快速追踪控制器（低层 MPC）来缓解预测误差，而不把全部压力放在线优化器上。

集中式 MPC 的优点是能同时优化全局目标、处理交互约束（碰撞、多艇协同）；缺点是计算量与通信要求高。适用于艇数较少或有强通信链路时。分布式/协同 MPC 把全局问题分解为局部子问题并通过消息交换（邻居状态、意图）或 ADMM/分解技术求解。局部问题形式相近但只负责本艇与邻居冲突约束。优点可扩展且容错；缺点需设计收敛与一致性机制，且通信延迟可能导致次优或不一致。本团队使用混合架构——高层（分配）集中式周期性运行（周期长），低层（局部避障与短期机动）分布式、高频运行。

为保证滚动策略长期可行，MPC 通常要求存在可行的终端约束或终端势函数 $Vf(x)$ 使得当规划到达

$$t = k + H$$

系统可在后续用某保守策略保持安全或返回基站，设计时需保证如果上一周期问题可行并按第一段执行，则下一周期仍能找到可行解（通过保守约束或软约束和备用方案实现）。其中关键度量为平均未覆盖量 U^* 、目标中和率、平均中和时间、能耗、碰撞次数、规划时延与在线解算成功率。

通过离线蒙特卡洛仿真与网格敏感性试验选择 Δt_{plan} 与 T_H ：常用流程为固定 Δt_{plan} （基于控制反应要求），试验不同 H 值在给定计算预算下的任务性能，并选择折衷点（性能增益 vs 计算成本）。评估 GA 的在线迭代次数上限、warm-start 策略对实时性能的贡献。仿真验证步骤如下：

- a) 在理想模型上验证；
- b) 加入目标运动噪声与观测噪声检验鲁棒性；
- c) 评估在通信丢失、单艇掉线的极端场景下的降级策略；
- d) 最后场地/硬件在环试验。

1.3.2.7 碰撞与安全约束模型

在协同航行/拦截任务中，碰撞与安全约束是必须显式建模的关键部分，它既包含几何上的最小安全距离约束，也包含能量/返航约束、紧急避障策略、以及在不确定性下的概率化安全保证。下面把这几类约束做系统化、可量化并给出多种在优化与控制器中可直接使用的数学表达、松弛/凸化方法与工程实施要点。

对任意两艘艇 $i \neq j$ 在任意时间 t ，要求位置信息满足最小分离距离 d_{coll} ：

$$\|p_i(t) - p_j(t)\| \geq d_{coll}, \quad \forall i \neq j, \forall t$$

其中， $p_i(t) \in R^2$ 是艇 i 在平面上的位置。该约束是非线性的（平方范数），在直接使用非线性规划（NLP）或非线性 MPC 时作为非线性不等式约束加入即可；在凸/线性优化中须进行近似或松弛。

在离散化时间点 $t_k = k\Delta t$ 下，几何约束变为：

$$\|p_i[k] - p_j[k]\| \geq d_{coll}, \quad \forall i \neq j, \forall k$$

常用于短时域优化（horizon H ）：

$$\|p_i[k + \ell] - p_j[k + \ell]\| \geq d_{coll}, \quad \ell = 0, \dots, H.$$

为保证可行性与数值稳定性，可把硬约束松弛为带惩罚的软约束，引入松弛变量 $s_{ij}[k] \geq 0$ ：

$$\|p_i[k] - p_j[k]\| \geq d_{coll} - s_{ij}[k], \quad s_{ij}[k] \geq 0$$

并在目标函数中加入大权重惩罚项 $\rho \sum_{i < j, k} s_{ij}[k]$ （ ρ 很大），或者用平方惩罚 $\rho \sum_{i < j, k} s_{ij}[k]^2$ 。常用于在线优化当中，确保当无法严格满足所有约束时系统仍能返回到安全退避策略，同时给出可解释的降级行为。

非线性项 $\|p_i - p_j\|$ 在优化中的直接处理代价高，团队采用一阶线性化（顺序凸规划 / SCP）：在当前参考轨迹 (p_i^0, p_j^0) 处线性化得到约束近似：

$$\|p_i^0 - p_j^0\| + \frac{(p_i^0 - p_j^0)^T}{\|p_i^0 - p_j^0\|} ((p_i - p_j) - (p_i^0 - p_j^0)) \geq d_{coll}$$

简化形式写为

$$2(p_i^0 - p_j^0)^T (p_i - p_j) \geq d_{coll}^2 - \|p_i^0 - p_j^0\|^2$$

对系统有可控输入的情况，使用控制屏障函数（Control Barrier Function, CBF）可在 QP 层面实时保证安全不变性。设安全函数

$$h_{ij}(x) = \|p_i - p_j\|^2 - d_{coll}^2$$

要求 $h_{ij}(x) \geq 0$ ，对控制仿射系统 $\dot{x} = f(x) + g(x)u$ ，CBB 要求：

$$\nabla h_{ij}(x) \cdot (f(x) + g(x)u) + \kappa h_{ij}(x) \geq 0$$

对于位置项，简化得

$$2(p_i - p_j)^T (v_i - v_j) + \kappa (\|p_i - p_j\|^2 - d_{coll}^2) \geq 0$$

把该线性不等式关于输入 u （角速度）写成线性约束后，可在 QP

$$\min \|u - u_{des}\|^2 \quad s.t. \text{ CBF 条件}$$

中实时求解，得到尽可能跟踪期望控制 u_{des} 的同时保证安全不变性。CBF 方法提供理论上的不变集保证（在满足可控性与正则条件下）。

在分布式实时避碰中，常使用速度障碍（Velocity Obstacle, VO）或最优互惠碰撞

避免（ORCA）方法。基本思想：规定可行速度集合 V_i （基于航速/操舵极限）；若当前速度 v_i 位于使在时间窗口 τ 内与另一艇碰撞的“速度锥”中，则需要变换速度使其脱离该锥。

通过 ORCA 给出对两艇 i, j 的线性半平面约束，保证双方以最小调整量避开碰撞：设相对位置 $p_{ij} = p_j - p_i$ 、相对速度 $v_{ij} = v_i - v_j$ 。计算最小修正向量 u 使得在时间 τ 内无碰撞，则要求新相对速度 $v_{ij} + u$ 不在碰撞锥内。ORCA 将该约束写作对 v_i 的线性半空间：

$$(v_i - v_i^{pref}) \cdot n \geq \frac{1}{2} u \cdot n$$

其中 n 表示碰撞锥边界的法向量， v_i^{pref} 为偏好的速度。每艘艇把来自所有邻居的 ORCA 半空间交集得到允许速度多边形并选择离 v_i^{pref} 最近的速度。ORCA 是分布式、计算快且常用于多机器人实时避障，但它对动力学和不可倒退性有近似假设。

现实中位置/控制存在测量与执行误差，硬性几何约束在概率意义下难以满足，于是引入概率（chance）约束，要求碰撞概率低于阈值 ϵ ：

$$Pr(\|p_i(t) - p_j(t)\| \geq d_{coll}) \geq 1 - \epsilon$$

由于相对位置 $r = p_i - p_j$ 近似高斯分布 $r \sim N(\mu_r, \Sigma_r)$ ，可采用“投影到法向”的近似处理：令 $u = \mu_r / \|\mu_r\|$ 为均值方向，投影后的标量随机变量 $z = u^T r$ 近似正态 $N(u^T \mu_r, u^T \Sigma_r u)$ 。则保证

$$Pr(z \geq d_{coll}) \geq 1 - \epsilon$$

等价于确定性约束：

$$u^T \mu_r - \Phi^{-1}(1 - \epsilon) \sqrt{u^T \Sigma_r u} \geq d_{coll}$$

其中 Φ^{-1} 是标准正态逆 CDF。该表达把概率约束转为均值与标准差的保守界，便于在线检查。在实际中，这种近似对相对位置方差小、均值明显非零的情况较可靠。若不愿做投影简化，可用保守界（例如 Chebyshev 不等式）得到更保守但无分布假设的界。

若 $E_i(t)$ 表示艇 i 的剩余能量（State of Charge），消耗速率可表示为瞬时功率函数 $P(v, \omega, \text{payload})$ ，离散化写为能量动力学：

$$E_i[k+1] = E_i[k] - P(v_i[k], \omega_i[k]) \Delta t - E_{op,i}[k],$$

其中 E_{op} 为传感/通信/加热等非推进功耗。为保证能量安全，需满足对任意时刻：

$$E_i[k] = E_{return}(p_i[k]) + E_{min}, \quad \forall k$$

其中， E_{min} 表示着陆/靠泊/应急所需的最小储备能量， $E_{return}(p_i)$ 是从位置 p 沿最省能量或最短时间路径返回最近载体/充电点所需的能量。由于计算精确能量消

耗困难，可用保守估计：

$$E_{return}(p) \approx e_{per_m} \cdot d_{return}(p)$$

其中， $d_{return}(p)$ 是（基于 Dubins 或航迹规划的）最短可行航程长度， e_{per_m} 是单位距离能耗经验估计（可随速度变化而变化）。更精确的连续表达为路径积分：

$$E_{return}(p) = \min \int_{\gamma} P((v(s), \omega(s))) ds$$

当艇群需轮换充电或返回母船时，需对充电/靠泊资源建模（容量、停靠时间窗口）。引入二元变量 $y_{i,r,t}$ 表示艇 i 在时间 t 与充电站/平台 r 预约停靠，则需满足排队与容量约束：

$$\sum_i y_{i,r,t} \leq C_r, \sum_{r,t} y_{i,r,t} \geq \text{required visits for } i$$

并保证艇在前往充电站的过程中其能量满足 $E_i(p) \geq E_{return}(p)$ 。该问题通常组合入高层任务分配（mTSP + vehicle routing with recharge）并用离线 GA/MILP 求解，在线以启发式或优先级规则调整。

在突发碰撞危险或通信失联时，采用有简单且快速可执行的紧急策略：定义优先级规则（如按艇剩余能量、任务重要性、编号等）在出现不可调和冲突时分配谁让路，以避免死锁。

1.3.3 创新性与合理性

在研究中，团队在技术路线的设计上充分融合了覆盖规划、组合优化、运动学约束路径规划以及博弈与学习驱动的在线决策方法，形成了一条具有理论支撑、工程可行性和实战适应性的完整路线。首先，在任务划分与分配环节，团队将复杂水域通过 *Boustrophedon* 单元分解切分为一系列凸或近凸的子区域，使得覆盖问题得以局部化处理，并基于这些子单元构建多旅行商问题（mTSP）模型，由改进遗传算法进行全局任务分配。这一方法将几何化的区域划分与组合优化的求解过程有机结合，显著降低了计算规模，便于并行化实现，同时保持了任务分配的全局最优性与灵活性。

在路径规划阶段，团队引入 RRT/RRT* 与 Dubins 曲线相结合的方法，将平台的运动学约束——如最小转弯半径 $R_{min} = 20m$ ——直接纳入路径生成过程，确保生成的轨迹既能满足覆盖要求，又在曲率、转向半径等方面完全可行，从而避免传统覆盖路径存在的锐角转向不可执行问题。该阶段还融合了路径平滑与代价综合优化策略，在长度、转向代价与能耗之间实现权衡。

在线决策与动态适应方面，团队将多无人艇区域封控问题抽象为离散时间动态博弈过程，在每个时间步利用博弈论分析局部均衡策略，并借助多智能体深度强化学

习 (MARL) 进行策略训练。通过中央训练—分布执行 (CTDE) 框架, 平台能够在不确定的对抗环境中学习到鲁棒性强、可迁移的轮换与机动策略。同时, 理论分析为奖励函数设计和策略收敛提供了指导, 使学习结果兼具可解释性和实用性。

该技术路线在合理性上有多重保障。首先, 采用模块化、层次化设计, 将“区域划分—任务分配—路径规划—在线对抗”四个环节解耦, 每个模块输出接口清晰, 方便独立优化与系统集成。其次, 算法选择上结合了成熟的组合优化方法 (GA/mTSP)、运动规划算法 (RRT/Dubins) 与博弈-学习混合策略, 针对 NP-hard 组合问题、连续运动学约束与动态不确定性问题分别提供了针对性解决方案。再次, 通过滑动时域规划与在线快速重规划相结合, 确保系统在面对敌方机动、通信延迟、环境扰动等情况时依然能保持任务有效性。

在创新性方面, 本路线不仅实现了不同算法在时空上的有机融合, 还在多个层面突破了传统方法的局限: 区域划分与任务分配的耦合降低了计算复杂度并提高了任务分配灵活性; 路径规划中嵌入运动学约束提升了可执行性; 动态博弈与 MARL 的结合兼顾了理论分析的解释性与深度学习的适应性。此外, 通过引入参数敏感性分析、消融实验与动态对抗测试, 该路线的有效性与鲁棒性可以得到量化验证。

综上所述, 本团队提出的技术路线在设计方法上体现了系统性与前瞻性, 创新性体现在算法融合与多层次优化的紧密结合, 合理性体现在各模块的可实现性与整体方案的可验证性。这一方案为无人艇集群在资源受限条件下实现持续、高效的区域封控提供了可行且高性能的技术支撑。

1.4 算法模型运行流程

需要绘制算法模型流程图, 并且用文字详尽描述算法模型的运行流程。

1.4.1 整体控制流程

在仿真系统启动时, 执行“初始化阶段”以创建所有战术实体并建立初始态势图。主要步骤与设计要点如下:

1.4.1.1 实体加载与状态初始化

创建实体: 为白方与黑方分别创建水面无人艇 (USV) 和舰载无人机 (UAV) 对象集合; 每个实体对象包含至少以下属性: 唯一 ID、阵营 (白/黑)、二维位置 $p = (x, y)$ 、航向 (角度 θ 或速度向量 v)、最大/当前速度 v_{max}, v 、能量/燃料状态 (电量百分比)、感知/通信半径、尺寸 (用于碰撞半径)。

初始参数赋值: 位置、航向和能量由外部任务规划或战场预案提供; 若无数据, 采用随机或规则化分布 (例如按防线均匀部署)。同时初始化全局时间计数器与各实体的状态机 (Idle/Patrol/Intercept/Return 等)。

状态监测字段: 为每实体维护最近 N 次速度/位置记录 (用于轨迹预测), 以及“最后一次检测到敌方时间”与“当前模式标签 (guard/forward)”。

1.4.1.2 基础布防策略

红线由一系列连通线段或一条折线表示（在地图上通常为一条边界线）。对每条红线段 AB ，先计算其单位法向量（朝向防守方或预定正向）。

在每条关键红线段上按均匀分布或根据威胁权重生成 5 个布防点 P_i 。生成方法：沿红线段以等距分割（端点与中间），或按威胁密度加权采样。

创建双层级防线：guard 防线是沿红线法向向外平移 5 km 的曲线：若红线点为 R ，则 guard 点为 $R + 5000 \cdot n^{\wedge}$ 。forward 防线在 guard 防线外侧再沿法向平移 20 km。两条与红线大体平行的曲线，用于不同的部署站位与态势判断。

将 USV 分配到离其当前位置最近/最适合的布防点或防线段；可根据航速、剩余能量与覆盖需求优化分配（例如使用贪心或最小化最大响应时间的分配算法）。每架 UAV 在深域负责一个闭环巡航航线，采用 4 点循环（四边形或椭圆近似），利于长时间巡航与覆盖稳定性。为每架 UAV 设定巡航高度、单圈时长与回航/refuel 规则（例如电量低于 20% 则自动返航或替换）。UAV 航线之间应用相位偏移或不同高度分层，避免同层冲突。

1.4.1.3 态势评估与模式切换

在无黑方目标时的时间大于 2 小时后，自动切换为 forward 模式。当检测到黑方目标时，计算黑方 USV 到红线的最短时间（ETA），从而根据 ETA 做出相应的评估与模式切换。若最小 ETA（任何敌方 USV 到红线的最短时间）大于 1.5 小时，则系统触发前推策略（forward）。若最小 ETA 小于或等于 1.5 小时，则触发回撤/守护策略（guard）。

碰撞检测与突防检测模块，该模块完成对碰撞距离的一个及时检测，以及对黑方 USV 的突防的一个机制判断。如图下所示：




图1 碰撞检测与突防检测流程图

流程启动，进入碰撞与突防检测的主循环，持续监测敌我双方实体的态势。系统首先进入碰撞检测模块，检查所有实体（己方 USV/UAV 与敌方 USV/UAV，或己方之间）是否存在潜在碰撞风险。系统依次遍历场景中所有可能的实体对（例如，己方 USV 与敌方 USV、己方 UAV 与敌方 UAV、己方内部实体等）。对每一对实体，都会计算它们的空间距离，并根据设定的碰撞半径判断是否触发碰撞预警。对于正在检查的两个实体，如果它们的欧氏距离小于或等于 100 米，则进入下一步处理。100 米是一个示例的安全阈值，具体值可根据船舶/UAV 的机动性、速度和传感器精度调整。如果距离大于 100 米，则直接判定为无碰撞风险，继续检查下一对实体。如果检测到距离小于或等于 100 米，则在系统中对该实体对进行“碰撞标记”。该标记可以用于后续避碰算法调用（如改变航向、减速等），也可以触发即时告警，标记信息通常包含：涉及的两个实体 ID、检测时间、距离、相对速度方向等。碰撞检测结束后，流程进入突防检测环节。该环节的目标是判断敌方是否有突破防线（红线）的行为。这里会判断敌方目标是否穿越了预设的红线监测点 A1~A6，检测方式可以是判断敌方是否进入点的保护半径，或是否在连续时间步内位置从红线外侧转到内侧。如果检测到有敌方穿越红线（A1-A6），则将突防成功计数器加 1，这个计数器用于记录敌方突防成功次数，后续可作为战术评估的输入数据（例如胜负判定、模式调整、威胁等级提升等）。当遍历完成所有碰撞检测与突防检测流程后，当前检测周期结束，等

待下一个循环。

1.4.1.4 任务分配核心逻辑

该分配逻辑依照执行周期(`assgin_period`)，在每个周期中对任务分配执行一次。

在初始状态下，白方 USV 的候选目标默认为空，当检测到新黑方的 USV 时，候选目标被切换为当前检测对象。在这基础上，触发博弈模型。针对该模型，存在限定的支付函数要素：120 分的锁定收益、-160 分的未覆盖乘法和存在的距离成本系数 0.0001（用于计算距离带来的成本代价）。在评分的系统体系上，通过代价矩阵计算出负权重来鼓励拦截，使 UAV 优先选择“最易被白方 USV 拦截”的黑方 USV。再通过匈牙利算法实现一对一的分配机制。流程如下图所示：




图2 作战任务逻辑算法流程图

流程启动，进入任务分配与搜索逻辑的主循环。该过程用于初始化作战实体并进行目标分配，以支持后续的防御、侦察和拦截任务。系统在启动阶段，会创建白方 USV（无人艇）与 UAV（无人机）的目标信息表，并初始化其位置、航向、速度、

能量等基础状态信息。系统根据任务优先级，为白方 USV 分配初始任务，分配方式通常按照队列顺序，或者根据当前防御阵位、威胁距离等因素来决定，任务类型包括：防御巡航、拦截、侦察、补给等。系统为白方 UAV 分配空中巡逻任务，主要用于远程侦察和威胁探测。根据 UAV 的实时探测信息，系统为每一架 UAV 建立敌方目标匹配关系，例如，如果 UAV 在航线上发现多个敌方目标，会根据距离、威胁等级、速度等条件选择最优目标进行跟踪。为了避免资源浪费，每个 UAV 或 USV 在一个任务周期内只跟踪一个优先目标，这样可以确保目标锁定稳定，同时避免多架平台重复跟踪同一目标而造成信息冗余。进入目标存在性判断，是：说明传感器探测到敌方实体，进入目标处置阶段，否：继续执行常规巡逻和搜索任务。如果存在目标，系统会计算敌方距离和状态（速度、航向、加速度等），基于时间预测敌方潜在威胁（预计到达红线的时间、可能的突防路线），更新任务列表，确保 USV/UAV 能根据最新情报动态调整任务。对于存在的敌方目标，系统会采用不同的处置方式：

- a) 追击目标：USV/UAV 直接向目标方向机动，缩短距离，执行拦截。
- b) 执行远程跟踪航线：保持安全距离，持续跟踪敌方位置与轨迹。
- c) 返回防御点：在威胁消失或任务结束时返回既定防御阵位。
- d) 采用防区巡逻待命：在敌方可能出现的区域进行预判巡航，节省能量并保持态势感知。
- e) 定位目标运动特点：分析敌方机动方式，为后续拦截或防御部署提供决策依据。

最后，系统会输出当前周期的任务分配结果，包括每个 USV/UAV 当前目标编号与位置；执行的具体任务类型；预计的目标到达时间与拦截时间。这些信息会同步到指挥控制模块，用于后续作战判断。

1.4.1.5 运动学推进（step_kinematics）

黑方 USV 采用最直接的进攻策略，其航向实时调整为指向红线最近点，并保持最大允许航速直线驶向该点。当探测系统或 UAV 提供了目标位置时，白方 USV 进入拦截模式。

如果当前没有有效目标（或目标被遮蔽、丢失跟踪），白方 USV 进入布防模式。虽然 UAV 不直接参与拦截推进，但它们在 step_kinematics 中会同步更新位置以保持巡逻航线或跟踪目标，并将实时情报反馈给态势评估模块，确保 USV 的拦截决策具有最新数据支撑。

感知更新模块流程如下：




图3 探测与目标更新流程图

系统开始执行探测任务，进入周期性的目标搜索与状态更新循环。白方水面无人艇（USV）首先在半径 20 km 的探测区域内搜索目标，系统会遍历探测到的所有黑方实体，判断是否进入交战条件。若目标存在，则进入下一步记录；若无目标，则直接跳至 UAV 探测步骤。一旦首次探测到黑方目标，系统会记录该时间戳，用于后续态势评估和 ETA 计算。白方舰载无人机（UAV）执行远距离探测任务，探测半径为 60 km，扫描扇区角度为 $\pm 30^\circ$ 。系统同样会模拟黑方的探测行为，黑方探测半径为 30 km。基于当前目标位置、丢失时间以及战术任务，系统会规划 UAV 的下一步巡逻扇区或航点，若目标已丢失，则 UAV 会向预测目标位置的方向延伸搜索。最后，将白方 USV、白方 UAV 以及黑方的最新探测状态同步更新到全局态势数据库。完成一次完整探测周期，等待下一时间步（Time Step）再次执行。

首先先基于现存电量来进行一个基础判断，在满足 20%以上电量的前提条件下，如果存在可分配黑方 USV, UAV 采取追击目标的行动策略。如果不存在，UAV 采取深域巡航模式进行闭环巡航。




图4 UAV 运动学行为算法图

1.4.2 UAV 能量管理流程 (energy.py)

在整个对抗仿真过程中，无人机（UAV）的能量状态采用连续的充放电模型进行模拟与管理，以确保任务执行的可持续性，并在能量不足时自动触发返航与充电逻辑。当 UAV 处于空中飞行状态时，每秒消耗 1/7200 单位能量。该设定等价于在持续飞行 2 小时（7200 秒）后能量完全耗尽（SOC=0）。放电过程与任务类型无关，视为恒定速率消耗，便于简化能量预测。当 UAV 在甲板上（停放于白方 USV 甲板）且处于充电状态时，每秒恢复 1/18000 单位能量。该速率意味着从完全耗尽到充满需要 5 小时（18000 秒）。充电过程假设为稳定输入，不受天气、甲板条件或电源限制影响。

返航逻辑的核心目标是防止 UAV 因能量耗尽而坠落，同时合理分配有限的甲板资源，避免返航冲突。当 UAV 当前能量水平（SOC）小于或等于阈值 `uav_land_soc` 时，返航逻辑被触发。筛选条件为：从所有白方 USV 中筛选出 空闲且未被占用的甲板，作为可选着舰目标。已经有 UAV 占用（在甲板充电）或处于“已被预约”状态

的甲板将被排除。结合优先级排序，最近距离优先和已预留甲板优先，以减少能量消耗和返航时间，保证返航计划稳定性。具体算法流程如下：




图5 UAV 能量管理流程图

1.4.3 博弈决策模型 (game.py)

策略生成模块的核心任务是基于当前的态势感知结果与任务目标，为自主作战平台（如 USV、UAV）动态分配行为模式。该模块根据传感器数据、敌方位置以及任务优先级，生成三类核心策略：

策略类型	条件	目标
Lock	黑方在探测范围内	指定黑方 ID
Maintain	保持当前状态	None
Evade	规避威胁（暂未实现）	None

表 1 核心策略表

Lock 策略是进攻和防御的关键切入点，它不仅会锁定目标 ID，还会在后续的运动学推进（step_kinematics）中影响路径规划与拦截点计算。

Maintain 策略确保系统在态势平稳时不会进行多余的策略切换，减少资源浪费。

Evade 策略虽然暂未实现，但其接口已保留，可后续结合威胁等级评估与路径避障算法实现。

纳什均衡求解流程用于在多方博弈环境下（例如多 USV、多 UAV 与敌方平台同时行动），计算在当前态势下的最优策略组合，使得各方均无法通过单方面改变策略而获得额外收益。流程概述如下：




图6 纳什均衡求解流程图

冻结与锁定模块（lock.py）主要负责在策略执行过程中目标状态的固定与更新，是“Lock 策略”的核心实现部分。它的功能分为两个主要环节：

- 冻结（Freeze）：**策略生成模块下发“Lock”指令并指定目标 ID 后，冻结模块会将该目标标记为“冻结状态”，禁止其他模块随意更换目标。冻结的意义在于保持任务连贯性，避免因短期态势波动频繁切换目标，造成拦截失败。冻结时间可设置为固定值。
- 锁定（Lock）：**锁定状态下，系统会持续跟踪目标的实时位置与运动参数。若目标丢失（超出探测范围或被摧毁），会解除锁定并将状态反馈回策略生成模块，以便重新选择目标。在锁定期间，lock.py 会与运动学推进模块（step_kinematics）交互，实时更新拦截点计算。

流程概述如下：




图7 冻结与锁定流程图

1.5 实际应用中的工程方法

1.5.1 模块化设计与解耦合

系统在设计阶段即采用了严格的模块化架构，将整体功能划分为多个相对独立的功能模块，每个模块各司其职：

- 运动控制模块 (Kinematics Control)：**负责 USV (无人水面艇) 与 UAV (无人机) 的运动学计算，包括航向调整、速度控制和拦截路径修正等。
- 能量管理模块 (Energy Management)：**负责 UAV 的能量消耗与补给逻辑，包括放电、充电模型以及低电量返航决策。
- 任务分配模块 (Task Assignment)：**基于博弈论的任务分配策略，动态决定

每个平台的作战任务与目标分配。

- d) 路径规划模块 (Path Planning): 生成闭环航点、布防点和扫描航线, 保证平台在巡逻、拦截与防御中的路径高效且无冲突。
- e) 感知与通信模块 (Sensing & Communication): 整合多传感器探测数据, 并实现多平台间信息共享与指令分发。

为了降低系统耦合度, 这些模块通过统一的数据结构进行交互, 确保数据接口清晰且稳定。这样不仅便于不同团队并行开发和调试, 还能在后续升级或替换某个模块时, 不影响整个系统的正常运行。工程上, 这种模块化与接口标准化的设计, 大幅提升了可维护性与可扩展性。

1.5.2 基于博弈论的任务分配策略

任务分配逻辑采用了静态博弈模型, 以实现多 USV 协同作战时的最优目标分配。该模型综合考虑以下因素:

- a) 锁定收益: 优先确保关键目标被拦截或持续跟踪。
- b) 未覆盖惩罚: 惩罚那些未被分配到防御或拦截的威胁。
- c) 距离代价: 优先分配距离较近的平台执行任务, 以提升响应速度并降低能耗。

在策略求解阶段, 系统首先尝试寻找纯策略纳什均衡, 即所有平台的策略组合都稳定且互不冲突; 若不存在纯策略解, 则使用复制子动态 (Replicator Dynamics) 近似混合策略均衡, 以确保在实时或准实时环境下获得可行的、稳定的分配方案。这种基于博弈论的任务分配在工程上的合理性体现在:

- a) 计算简洁, 可支持实时决策。
- b) 适应性强, 能动态应对平台或目标的增减。
- c) 避免冲突, 减少多平台抢占同一目标的情况

1.5.3 闭环航点与自动返航机制

为了确保巡逻任务的连续性, UAV 在执行过程中遵循闭环扫描航线。该航线经过精心设计, 既能覆盖防御区域的深域部分, 又能在目标丢失的情况下继续巡逻, 防止空白区出现。能量管理方面, 系统引入了自动返航与充电机制:

- a) 当 UAV 的电量低于设定阈值 (uav_land_soc) 时, 系统会自动触发返航, 并选择最近且可用的甲板作为降落点。
- b) UAV 在甲板上进行自动充电, 充电完成后等待新的任务指令或再次起飞。
- c) 起飞条件可根据任务需求灵活配置, 例如 SOC 阈值、任务紧急度或延迟时间。

工程上, 这种设计带来的好处包括:

- a) 航线有序, 避免巡逻路径混乱。
- b) 鲁棒性强, 低电量自动返航避免失联或坠毁风险。

- c) 充电与调度逻辑清晰，方便实际系统部署与维护。

1.5.4 动态布防与前推策略

USV 防御任务采用动态布防策略，即在红线内侧建立防御阵线，并可根据敌方动态进行前推：

- a) 布防点动态调整：当敌方接近时，防御点会向前推进，压缩敌方的行动空间。
- b) 前推时机判定：由敌方与防线的距离及预计到达时间（ETA）共同决定，确保既能有效防御，又不冒进。
- c) 撤回逻辑：当敌方威胁解除或探测失败时，自动撤回至原布防线，以减少被反击风险。

这种动态防御机制在工程上具有高度适应性，能够快速响应战场态势变化，同时保持防御资源的高效利用。

1.5.5 能量与调度的统一管理

系统对能量与平台调度进行了统一管理，形成闭环控制：能量状态实时跟踪保证每个 UAV 的电量（SOC）会被持续监测，作为任务调度与返航触发条件的重要依据。甲板资源采用预约与占用机制管理，避免多个 UAV 同时返航造成冲突。

- a) 支持多 UAV 排队等待充电。
- b) 支持高优先级任务的抢占。
- c) 支持任务完成后的甲板资源自动释放。

这种统一管理的好处是：

- a) 提升整体任务执行效率，避免能源短缺造成任务中断。
- b) 保证甲板资源的高可用性与公平调度。
- c) 在多平台协同时，减少等待时间与资源浪费。

工程方法的综合优势可如下表所示：

工程方法	优势	应用场景
模块化设计	易维护、易扩展	多平台协同、复杂系统
博弈任务分配	决策合理、资源最优	多目标追踪、对抗场景
闭环航点与返航	巡逻稳定、系统鲁棒	长时间无人值守任务
动态布防	灵活适应战场变化	海域防御、区域监控
能量与调度统一	资源高效利用	无人机群调度、后勤管理

表 2 综合优势表

2 自测结果

在深入分析战术效果之前，有必要对仿真环境和关键参数进行系统性梳理，这构成了理解所有战术行为的基础。

2.1 无人艇与无人机系统配置分析

白方配置了一个由 5 艘无人艇 (USV) 和 5 架无人机 (UAV) 组成的协同系统：

- a) 白方无人艇 (USV)：数量为 5，机动速度恒定为 10m/s，最小转弯半径为 20km。其传感器系统具有两个核心参数：探测范围为半径 20km 的圆形区域，而锁定范围则扩展至半径 40km。这种设定揭示了一个重要的战术机制：白方 USV 在发现目标后，并不能立即进行锁定，而是需要通过机动进入更远的锁定区域。这表明白方的战术行动是一个多阶段过程：发现 → 机动 → 锁定。因此，匈牙利分配算法在计算成本时，不能仅仅考虑欧氏距离，还必须将进入锁定范围所需的机动路径和时间纳入考量。此外，白方 USV 的锁定成功率为 0.8，被锁定两次后将退出战斗，为对抗引入了概率性与不可逆的损失机制。
- b) 白方无人机 (UAV)：数量为 5，速度范围为 150m/s 至 20m/s，远高于 USV 的速度，使其具备了快速部署能力。其探测范围为 60km，且呈正中心 60 度扇形区域。UAV 的探测范围远超 USV，使其成为整个白方侦察体系的核心前置单元。其“接力循环同向探测”的巡逻策略，旨在以最小的重复覆盖，最大化对突破线的侦察效率。UAV 的电源管理机制也颇具深意：滞空时间为 2 小时，电量消耗速率为 50%/小时，充电速率为 20%/小时，且需要预留返航电量。这种非对称的电量机制强制 UAV 进行严格的任务窗口管理，迫使其必须在电量耗尽前返回任何一艘白方 USV 进行充电。这不仅是白方集群韧性 (Resilience) 的关键，也为整个系统增加了后勤调度这一复杂的子任务。

黑方无人艇在数量上与白方相等，也为 5 艘，其机动速度与白方相同，为 10m/s。黑方无人艇 (USV)：数量未知，但截图显示为 5 艘，其探测距离为 30km，最大锁定距离为 40km。值得注意的是，黑方的探测距离 (30km) 大于白方 USV 的探测距离 (20km)。这给予了黑方在单艇层面一定的侦察优势，理论上可以更早地发现接近的白方 USV。然而，从后续的仿真结果来看，由于白方无人机的广域侦察优势，黑方的这一单艇优势并未能转化为整体战术优势。黑方同样在被锁定两次后退出。

2.2 仿真过程与战术效果评估

2.2.1 模拟起始与无人机侦察阶段




图8 t=260s 仿真运行截图

仿真日志显示，此时白方和黑方无人艇数量均为 5，白方已派出 5 架无人机进行前置侦察。在坐标系中，白方无人艇和无人机重叠显示（蓝色方块）。此时，白方 USV 尚未进入任务区域，而黑方 USV 已位于任务区域的右侧，b_usv5 甚至已接近突破线。这一初期配置明确了战局的初始态势：黑方 USV 集群正试图突破防线，而白方则需要通过侦察获取敌情，并部署拦截。




图9 t=5350s 仿真运行截图

经过一段时间的模拟，白方 USV 集群已进入任务区域，并在无人机的指引下，开始向黑方 USV 集群方向移动。黑方 USV 此时已进一步深入。值得注意的是，白方 USV 已开始向左侧分散，显示出集群的初始战术部署。这个阶段的核心是情报获取。白方无人机利用其 60km 的广域探测范围和高速机动能力，在 USV 集群到达前就掌握了黑方的大致位置和数量，为白方 USV 的提前部署提供了宝贵的先发优势。这确保了白方能够规划拦截路径，而不是在任务区域内盲目搜索。

2.2.2 接触与首次分配阶段




图10 t=11560s 仿真运行截图

白方 USV 与黑方 USV 之间的距离已显著缩短，双方已进入各自的探测和锁定范围。白方 USV 集群已明显分散开来，呈现出一种包围态势，每个 USV 都朝着一个特定的黑方 USV 方向前进。




图11 t=12060s 仿真运行截图

日志显示白方已成功锁定黑方一次（白锁黑:1）。白方无人艇与黑方无人艇的距离进一步拉近，形成了清晰的一对一追击态势。例如，w_usv1 与 b_usv1，w_usv2 与 b_usv2，w_usv3 与 b_usv3，w_usv4 与 b_usv4，w_usv5 与 b_usv5，形成了两两对应的匹配关系。这正是匈牙利分配算法首次执行的结果。根据黑方 USV 的密集分布，白方集群很可能将欧氏距离作为成本函数，实现了距离最短的最优分配。

2.2.3 交战与首个目标锁定




图12 t=12600s 仿真运行截图

白方首次击中黑方（白->黑：1）。图片中，白方 USV 与黑方 USV 在任务区域内形成缠斗。白方 USV 正在向 b_usv5 机动，这可能意味着它是第一个被分配的目标之一。




图13 t=14370s 仿真运行截图

战局发生重大变化。日志显示，黑方无人艇数量从 5 变为 4，表明一艘黑方无人艇已被彻底清除。同时，白方对黑方的锁定次数达到了 8 次，但击中次数仍为 1 次。这强烈暗示了“锁定冻结”机制的生效。白方通过多次锁定（每次锁定成功概率为 0.8），最终完成了对一个目标的双次锁定，使其退出战斗。黑方目标的减少，触发了匈牙利算法的动态再分配。原先追击被消灭目标的白方 USV 需要被重新分配给剩余的 4 个目标，以继续保持对黑方集群的压力。从图片上看，白方 USV 集群已开始重新调整队形。此阶段也验证了博弈论追击算法的决策：在锁定一个目标并使其冻结后，白方选择了持续施压，最终将其清除。

2.2.4 战局推进与连续打击




图14 t=15580s 仿真运行截图

又一黑方 USV 被消灭，数量降至 3。值得关注的是，日志显示黑方成功锁定白方一次（黑->白: 1）。这表明黑方并非完全被动，其 40km 的锁定能力也对白方构成了威胁。被锁定的白方 USV 将进入 5 分钟的“冻结”状态，这考验了白方集群在损失一个单位战力时的应变能力。




图15 t=17140s 仿真运行截图

黑方无人艇数量急剧减少到 1 艘，白方击中数达到 5 次。图中，b_usv5 是唯一幸存的黑方无人艇，它位于任务区域的左上方，远离主战场。




图16 t=18270s 仿真运行截图

白方 USV 集群开始向幸存的 b_usv5 集中。此时，匈牙利分配算法的分配逻辑变得简单明了：所有剩余的白方 USV 都将追击唯一目标为最优解。这展示了算法在从多对多到多对一的复杂战局变化中的健壮性。

2.2.5 最终战果与残局处理




图17 t=20140s 仿真运行截图

日志显示黑方无人艇数量为 1，白方成功消灭大部分敌方目标。仿真日志记录了白方共击中黑方 10 次，黑方击中白方 0 次，白方锁定黑方 8 次，黑方锁定白方 1 次。最终结果证明了白方算法组合的整体有效性。无人机的前置侦察提供了情报优势，匈牙利分配算法确保了资源 (USV) 在不同战局下的最优利用，避免了“重复追击”或“无人追击”的资源浪费，而博弈论追击算法的决策则使得白方能够高效地清除已锁定目标，而不是让其“解冻”后重新投入战斗。

2.3 核心算法性能深度分析

从仿真过程来看，匈牙利分配算法在白方集群战术中起到了决定性的作用：

- a) 动态分配效率：图片分析显示，每当黑方目标被消灭，白方 USV 集群都能迅速调整队形，对剩余目标进行重新分配。这证明了算法在动态环境中的实时响应能力，能够根据战场态势的变化快速优化资源配置。
- b) 成本函数优化：在该简化模型中，由于没有静态障碍物，欧氏距离作为成本函数可能足以实现有效分配。然而，在更复杂的真实海战环境中，USV 的最小转弯半径为 20km 是一个重要的运动学约束。这意味着直线距离并非实际可行的航行路径。一个更高级的成本函数可能需要结合 A* 搜索算法或 Dijkstra 算法等航路规划技术，计算出考虑运动学约束后的实际航行时间或距离，从而使分配方案更加贴近实际。
- c) 应用局限性：匈牙利算法是解决多对多匹配的有效方案，但其计算复杂度为 $O(n^3)$ 。当集群规模 n 变得非常大时，实时计算可能会成为一个挑战。此外，当黑方目标数量远大于白方 USV 时，算法需要一个额外的逻辑来决定如何对部分目标进行优先分配，或者如何处理“未能分配”的白方 USV，这是未来算法扩展需要考虑的问题。

博弈论追击算法的决策逻辑在本模拟中得到了验证：

- a) 决策模型分析：仿真结果显示，白方在锁定黑方 USV 后，选择了持续施压直至其退出。这表明博弈论算法的收益函数可能被设定为倾向于“快速消灭已有威胁”。这种策略的优势在于，能够迅速减少敌方数量，从而降低白方集群所面临的整体威胁。
- b) 模型有效性：博弈论决策的有效性高度依赖于对对手行为的预测。在该模拟中，黑方似乎没有采取复杂的战术，例如集中火力攻击单个白方 USV 或利用诱饵进行规避。因此，白方基于“快速清除”的策略取得了成功。然而，在更复杂的对抗中，例如黑方采取集火攻击策略（正如日志中黑方成功锁定白方一次所暗示的），白方的博弈决策可能需要调整，以平衡“攻击”与“自保”之间的关系。
- c) 扩展性讨论：未来的博弈论算法模型可以引入更复杂的变量，如目标的价值等级、攻击成功率随距离衰减等，以构建更贴近实际的收益函数。例如，当黑方集群中存在一个“高价值目标”（如指挥艇）时，即使其距离较远，博弈论算法也应将其作为优先攻击对象。

2.4 模拟模型准确性与有效性分析

白方 UAV 的广域侦察能力（60km）与白方 USV 的锁定范围差异（40km）共同构建了一个合理的战术层次结构。这使得白方能够利用 UAV 进行远距离侦察，并利用 USV 进行近距离锁定与打击。这种分层协同机制在实战中具有重要的参考价值。“被锁定两次则退出”的规则，虽然简化，但有效地模拟了无人艇的“功能失效”或“被击沉”，为算法提供了一个清晰的“胜利”或“失败”条件，便于评估算法效果。

本报告通过对仿真截图的详尽分析，系统性地评估了白方无人艇集群所采用的匈牙利分配算法与博弈论追击算法的战术效能。以及测试集中每个案例运行时的日志文件（按照测试集文件夹中的 logDemo.json 格式）作为附件打包提交。

3 使用说明

3.1 运行环境

1. Python 版本:

- a) 支持 Python 3.9+ (兼容 3.10/3.11/3.12)
- b) 额外依赖: 仅日志回放需安装 matplotlib。(bash 复制“python3 -m pip install matplotlib”)。

2. 系统要求:

需从项目根目录 (sim_main.py 同级目录) 运行命令, 确保 uavsim/ 子目录包含 __init__.py 文件。

3.2 代码目录结构




图18 代码目录结构图

关键提示: 所有命令必须在项目根目录 (与 sim_main.py 同级) 执行。

3.3 运行步骤

3.3.1 运行仿真 (生成日志)

最小参数命令 (仅需任务区+黑方方案):

```
python3 sim_main.py \
-- area ./任务区域.json \
-- black-plan ./方案1 - 黑方艇数量_3.json \
-- stream
```

输出文件包括日志文件: ./logDemo_out.json和指标文件: ./metrics.json

完整参数说明如下表:

参数	作用	是否必选	默认值
--area	任务区域配置文件	是	无
--black-plan	黑方方案文件	是	无
--stream	实时流式输出	否	关闭
--max-steps	最大仿真步数	否	1000

参数	作用	是否必选	默认值
--seed	随机数种子	否	None

表 3 完整参数说明表

3.3.2 日志回放可视化

```
python3 viz_log.py \
--log ./logDemo_out.json \
--area ./任务区域.json \
--metrics ./metrics.json \
--fps 200
```

可视化界面功能：

a) 右上角 HUD：

- 白方/黑方锁定状态（当前/累计）
- 首次突防时间
- 碰撞计数（当前/累计）

b) 左上角 HUD：实时实体数量（白 USV/黑 USV/UAV）

参数说明见下表：

参数	作用	是否必选	默认值
--log	仿真生成的日志文件	是	无
--area	任务区域配置文件	是	无
--metrics	指标文件	是	无
--fps	回放帧率（速度控制）	否	60
--save-mp4	输出视频文件（如开启）	否	关闭

表 4 可视化界面参数说明表

3.4 常见问题解决

常见问题解决说明见下表：

问题现象	解决方案
ImportError 或找不到模块	确认在项目根目录运行；检查 uavsim/ 下是否存在 <code>__init__.py</code>
中文显示为方块	安装本地中文字体（脚本会自动尝试常见字体）
无轨迹显示	复查是否使用本次仿真生成的 <code>logDemo_out.json</code> 和 <code>metrics.json</code>
黑方方案加载失败	检查 JSON 文件路径及格式（确保键名如 <code>"black_uavs"</code> 正确）

表 5 常见问题解决说明表

3.5 高级配置

如需修改仿真逻辑（如控制算法、实体行为），可编辑以下模块：

- a) 控制策略：uavsim/control/ 下的 PID/路径规划算法
- b) 实体参数：uavsim/entities/UAV.py 中的动力学模型
- c) 感知模型：uavsim/sensing/ 下的传感器逻辑

修改后需重新运行 `sim_main.py` 生成日志验证效果。

3.6 关键参数

关键参数见下表：

参数名	默认值	单位	参数含义	关键影响领域
<i>dt</i>	10	秒	仿真时间步长	基础仿真

参数名	默认值	单位	参数含义	关键影响领域
<i>duration</i>	36000	秒	仿真总时长（10 小时）	基础仿真
<i>lock_success_prob</i>	0.8	概率值	雷达锁定成功概率	对抗机制
<i>uav_land_soc</i>	0.2	电量比例	无人机触发返航的电量阈值（20%）	能源管理
<i>grid_cell_km</i>	5.0	公里	邻域加速网格的单元大小	性能优化
<i>assign_period</i>	60	秒	任务分配调度周期	任务分配
<i>assign_horizon</i>	3600	秒	任务分配预测时间范围	任务分配
<i>guard_offset_km</i>	5.0	公里	红线前沿布防偏移距离	防御策略
<i>uav_cruise_speed</i>	120	米/秒	无人机巡航速度（约 432km/h）	运动控制
<i>uav_autolaunch</i>	True	布尔值	电量满后自动起飞	无人机行为
<i>uav_autolaunch_delay</i>	30	秒	自动起飞延迟时间	无人机行为
<i>seed</i>	42	-	随机数生成器种子	实验可复现

表 6 关键参数表